

梦中控制：学习行为 通过潜在想象

Danijar Hafner *
University of Toronto
Google Brain

Timothy Lillicrap
DeepMind

Jimmy Ba
University of Toronto

Mohammad Norouzi
Google Brain

摘要

学得的世界模型可以概括智能体的经验，从而帮助智能体学习复杂行为。随着深度学习的发展，从高维感知输入中学习世界模型已逐渐可行；但如何基于世界模型得到有效行为，仍有多种选择。本文提出 Dreamer，这是一种强化学习智能体，能够仅依靠潜在空间中的想象，从图像输入解决长时程任务。具体而言，我们在学得的世界模型的紧凑状态空间中生成想象轨迹，并将学得的状态价值的解析梯度沿这些轨迹反向传播，从而高效学习行为。在 20 个具有挑战性的视觉控制任务上，Dreamer 在数据效率、计算时间和最终性能方面均超过了已有方法。

1 引言

智能体即使从未两次遇到完全相同的情境，也能够复杂环境中达成目标。这种能力依赖于从既有经验中形成关于世界的表示，并将其泛化到新的情境。世界模型为这种能力提供了一种明确形式：它用能够预测未来的参数化模型来表示智能体对世界的认识。

当感知输入是高维图像时，潜在动力学模型可以把观测抽象到紧凑的状态空间中，并在该空间内向前预测 (Watter et al., 2015; Oh et al., 2017; Gregor et al., 2019)。与直接在图像空间预测相比，潜在状态占用的内存更小，因此可以并行想象数千条轨迹。随着深度学习和潜变量模型的发展，学习有效的潜在动力学模型正变得越来越可行 (Krishnan et al., 2015; Karl et al., 2016; Doerr et al., 2018; Buesing et al., 2018)。

从动力学模型导出行为有多种方式。常见做法是用参数化策略最大化想象回报 (Sutton, 1991; Ha and Schmidhuber, 2018; Zhang et al., 2019)，或采用在线规划 (Chua et al., 2018; Hafner et al., 2018)。但如果只考虑固定想象时域内的奖励，智能体容易得到短视行为 (Wang et al., 2019)。此外，已有工作通常使用无导数优化来提高对模型误差的稳健性 (Ebert et al., 2017; Chua et al., 2018; Parmas et al., 2019)，而没有充分利用神经网络动力学提供的解析梯度 (Henaff et al., 2019; Srinivas et al., 2018)。

本文提出 Dreamer，这是一种完全通过潜在想象从图像中学习长时程行为的智能体。我们设计了新的 actor-critic 算法，在高效利用神经网络动力学的时候，也能考虑超出想象时域的回报。具体而言，我们在学得的潜在空间中预测状态价值和动作，如图 1 所示。价值函数通过想象奖励优化 Bellman 一致性；策略则通过将价值的解析梯度沿动力学反向传播来最大化价值。

与在线学习或依赖经验回放的 actor-critic 算法相比 (Lillicrap et al., 2015; Mnih et al., 2016; Schulman et al., 2017; Haarnoja et al., 2018; Lee et al., 2019)，世界模型可以在过去经验之间进行插值，并提供多步回报的解析梯度，从而更高效地优化策略。

*通讯作者：Danijar Hafner <mail@danijar.com>.




图 1: Dreamer 从过去经验中学习世界模型，并在其潜在空间中沿想象轨迹反向传播价值估计，从而高效学习具有长时程考虑的行为。




图 2: 我们实验使用的 20 个视觉控制任务中, 图中展示了其中 5 个任务的图像观测。这些任务覆盖多种挑战, 包括接触动力学、弱奖励、多自由度控制和 3D 环境。此前部分任务尚未被世界模型方法解决。

本文的主要贡献如下:

- **以潜在想象学习长时程行为** 如果只使用有限的想象时域, 基于模型的智能体可能会变得短视。我们通过同时预测动作和状态价值来缓解这一限制。完全在潜在空间中通过想象训练, 使我们能够沿潜在动力学传播解析价值梯度, 从而高效学习策略。
- **视觉控制的经验性能** 我们将 Dreamer 与现有表示学习方法结合, 并在图像输入的 DeepMind Control Suite 上评估, 如图 2 所示。在所有任务使用相同超参数的情况下, Dreamer 在数据效率、计算时间和最终性能方面超过了此前的基于模型和无模型智能体。

2 用世界模型进行控制

强化学习 我们将视觉控制表述为部分可观测马尔可夫决策过程 (POMDP)。时间步为离散的 $t \in [1; T]$, 动作是连续向量 $a_t \sim p(a_t | o_{<t}, a_{<t})$, 观测为高维图像, 并带有标量奖励 $o_t, r_t \sim p(o_t, r_t | o_{<t}, a_{<t})$ 。目标是学习一个智能体, 使期望累计奖励 $E_p(\sum_{t=1}^T r_t)$ 最大化。图 2 展示了本文使用的任务。

智能体组件 在想象中学习的智能体通常包含三个部分: 动力学学习、行为学习和环境交互 (Sutton, 1991)。Dreamer 通过在世界模型的紧凑潜在空间中预测假想轨迹来学习行为。如图 3 和 算法 1 所示, 在智能体生命周期内, Dreamer 反复执行以下操作, 这些操作也可以交替或并行进行:

- 从过去经验构成的数据集中学习潜在动力学模型, 用动作和过去观测预测未来奖励。我们在 节 4 中讨论用于学习潜在动力学的现有方法。
- 从预测出的潜在轨迹中学习动作模型和价值函数模型, 如 节 3 所述。价值函数模型通过想象奖励优化 Bellman 一致性, 动作模型则通过神经网络动力学反传价值估计的梯度来更新。
- 在真实环境中执行学得的动作模型, 收集新经验并扩充数据集。

潜在动力学 Dreamer 使用由三个组件构成的潜在动力学模型。表征模型编码观测和动作, 生成具有马尔可夫转移的连续向量模型状态 s_t (Watter et al., 2015; Zhang et al., 2019; Hafner et al., 2018)。转移模型在看不到未来观测的情况下预测未来模型状态; 奖励模型根据模型状态预测奖励。

$$\begin{aligned}
 \text{表征模型:} & \quad p(s_t | s_{t-1}, a_{t-1}, o_t) \\
 \text{转移模型:} & \quad q(s_t | s_{t-1}, a_{t-1}) \\
 \text{奖励模型:} & \quad q(r_t | s_t).
 \end{aligned} \tag{1}$$

我们用 p 表示在真实环境中产生样本的分布, 用 q 表示学得模型。具体而言, 转移模型让我们能够在紧凑潜在空间中向前预测, 而不需要观测或想象对应图像。这降低了内存占用, 也使快速预测数千条想象轨迹成为可能。

该模型类似于非线性 Kalman 滤波器 (Kalman, 1960)、潜在状态空间模型, 或带连续状态的 HMM。不过, 它以动作为条件并预测奖励, 因此智能体可以在不实际执行动作的情况下, 想象候选动作序列可能带来的结果。




图 3: Dreamer 的组成部分。(a) 基于过去经验构成的数据集, 智能体学习将观测和动作编码为紧凑的潜在状态 (●), 例如通过重建来学习, 并预测环境奖励 (★)。 (b) 在紧凑潜在空间中, Dreamer 预测状态价值 (★) 和动作 (●), 并通过想象轨迹反向传播梯度, 使未来价值预测最大化。 (c) 智能体编码当前 episode 的历史, 计算当前模型状态, 并预测下一步将在环境中执行的动作。智能体伪代码见 算法 1。

3 学习行为通过潜在想象

Dreamer 在学得的世界模型的紧凑潜在空间中学习长时程行为, 并高效利用神经网络形式的潜在动力学。为此, 我们通过重参数化, 将多步回报的随机梯度沿动作、状态、奖励和价值的神经网络预测反向传播。本节介绍本文的主要贡献。

想象环境 潜在动力学定义了一个完全可观测的马尔科夫决策过程 (MDP; Sutton, 1991), 因为紧凑模型状态 s_t 具有马尔科夫性。我们用 τ 表示想象轨迹中的时间索引。想象轨迹从真实模型状态 s_t 出发, 这些状态来自智能体过去经验中的观测序列; 随后轨迹按照转移模型 $s_\tau \sim q(s_\tau | s_{\tau-1}, a_{\tau-1})$ 、奖励模型 $r_\tau \sim q(r_\tau | s_\tau)$ 和策略 $a_\tau \sim q(a_\tau | s_\tau)$ 的预测向前展开。目标是在策略参数上最大化期望想象回报 $E_q(\sum_{\tau=t}^{\infty} \gamma^{\tau-t} r_\tau)$ 。

算法 1: Dreamer

用 S 个随机种子 episode 初始化数据集 $\mathcal{D}$ 。	模型组件	
随机初始化神经网络参数 θ, ϕ, ψ 。	表征	$p_\theta(s_t s_{t-1}, a_{t-1}, o_t)$
while not converged do	转移	$q_\theta(s_t s_{t-1}, a_{t-1})$
for update step $c = 1..C$ do	奖励	$q_\theta(r_t s_t)$
// 动态学习	动作	$q_\phi(a_t s_t)$
从 $\mathcal{D}$ 中抽取 B 条数据序列 $\{(a_t, o_t, r_t)\}_{t=k}^{k+L} \sim \mathcal{D}$ 。	价值	$v_\psi(s_t)$
计算模型状态 $s_t \sim p_\theta(s_t s_{t-1}, a_{t-1}, o_t)$ 。	超参数	
使用表征学习更新 θ 。	种子回合	S
// 行为学习	收集间隔	C
从每个 s_t 想象轨迹 $\{(s_\tau, a_\tau)\}_{\tau=t}^{t+H}$ 。	批量大小	B
预测奖励 $E(q_\theta(r_\tau s_\tau))$ 和价值 $v_\psi(s_\tau)$ 。	序列长度	L
按 Equation 6 计算价值估计 $V_\lambda(s_\tau)$ 。	想象时域	H
更新 $\phi \leftarrow \phi + \alpha \nabla_\phi \sum_{\tau=t}^{t+H} V_\lambda(s_\tau)$ 。	学习率	α
更新 $\psi \leftarrow \psi - \alpha \nabla_\psi \sum_{\tau=t}^{t+H} \frac{1}{2} \ v_\psi(s_\tau) - V_\lambda(s_\tau)\ ^2$ 。		
// 环境交互		
$o_1 \leftarrow \text{env.reset}()$		
for time step $t = 1..T$ do		
根据历史计算 $s_t \sim p_\theta(s_t s_{t-1}, a_{t-1}, o_t)$ 。		
用动作模型计算 $a_t \sim q_\phi(a_t s_t)$ 。		
在动作中加入探索噪声。		
$r_t, o_{t+1} \leftarrow \text{env.step}(a_t)$ 。		
将经验加入数据集 $\mathcal{D} \leftarrow \mathcal{D} \cup \{(o_t, a_t, r_t)_{t=1}^T\}$ 。		




图 4: 想象时域。我们比较 Dreamer、无价值预测的动作模型, 以及使用 PlaNet 在线规划三种方案的最终性能。学习状态价值模型来估计想象时域之外的奖励, 使 Dreamer 对时域长度更鲁棒。所有智能体都使用像素重建进行表征学习, 并采用动作重复 $R = 2$ 。

动作和价值函数模型 考虑限时域 H 的想象轨迹。Dreamer 使用 actor-critic 方法学习行为, 使其能够考虑超出想象时域的奖励。为此, 我们在世界模型的潜在空间中学习一个动作模型和一个价值模型。动作模型实现策略, 目标是预测能够解决想象环境的动作。价值模型估计动作模型从每个状态 s_τ 出发所能获得的期望想象回报:

$$\begin{aligned} \text{动作模型:} \quad & a_\tau \sim q_\phi(a_\tau | s_\tau) \\ \text{价值模型:} \quad & v_\psi(s_\tau) \approx \mathbb{E}_{q(\cdot | s_\tau)} \left(\sum_{\tau=t}^{t+H} \gamma^{\tau-t} r_\tau \right). \end{aligned} \quad (2)$$

动作模型和价值模型像典型策略迭代那样协同训练: 动作模型试图最大化价值估计, 而价值模型则拟合会随动作模型变化而变化的价值估计。

动作模型和价值模型均采用全连接神经网络, 参数分别为 ϕ 和 ψ 。动作模型输出一个由 $\tanh$ 变换的高斯分布 (Haarnoja et al., 2018), 其充分统计量由神经网络预测。这允许使用重参数化采样 (Kingma and Welling, 2013; Rezende et al., 2014), 即把采样动作视为神经网络输出的确定性函数, 从而可以解析梯度穿过采样操作:

$$a_\tau = \tanh(\mu_\phi(s_\tau) + \sigma_\phi(s_\tau)\epsilon), \quad \epsilon \sim \text{Normal}(0, \mathbb{I}). \quad (3)$$

值估计 为了学习动作模型和价值模型, 我们需要估计想象轨迹 $\{s_\tau, a_\tau, r_\tau\}_{\tau=t}^{t+H}$ 的状态价值。这些轨迹从模型状态 s_t 分支出来; s_t 来自智能体经验数据集中采样的序列批次, 并使用动作模型采样出的动作向前预测 H 个想象步。状态价值可以用多种方式估计, 从而在偏差和方差之间折中 (Sutton and Barto, 2018):

$$V_R(s_\tau) \doteq \mathbb{E}_{q_\theta, q_\phi} \left(\sum_{n=\tau}^{t+H} r_n \right), \quad (4)$$

$$V_N^k(s_\tau) \doteq \mathbb{E}_{q_\theta, q_\phi} \left(\sum_{n=\tau}^{h-1} \gamma^{n-\tau} r_n + \gamma^{h-\tau} v_\psi(s_h) \right) \quad \text{with} \quad h = \min(\tau + k, t + H), \quad (5)$$

$$V_\lambda(s_\tau) \doteq (1 - \lambda) \sum_{n=1}^{H-1} \lambda^{n-1} V_N^n(s_\tau) + \lambda^{H-1} V_N^H(s_\tau), \quad (6)$$

其中期望在想象轨迹下估计。 V_R 只累加从 τ 到想象时域末端的奖励, 并忽略其后的奖励; 这允许在没有价值模型的情况下学习动作模型, 我们在实验中将其作为消融对比。 V_N^k 使用学得的价值模型估计 k 步之后的奖励。 Dreamer 使用 V_λ , 即不同 k 的估计值的指数加权平均, 以平衡偏差和方差。图 4 表明, 在想象中学习价值模型可以让 Dreamer 解决长时程任务, 同时对想象时域长度保持稳健。所有任务的实验细节和结果见 节 6。




图 5: 长时程预测的重建结果。我们将表征模型应用于两条留出轨迹的前 5 帧图像, 然后在只给定动作的情况下, 使用潜在动力学向前预测 45 步。循环状态空间模型 (RSSM; Hafner et al., 2018) 能够进行较准确的长时程预测, 使 Dreamer 可以在紧凑潜在空间中学习成功行为。

学习目标 为了更新动作模型和价值模型, 我们首先为想象轨迹上的所有状态 s_τ 计算价值估计 $V_\lambda(s_\tau)$ 。动作模型 $q_\phi(a_\tau | s_\tau)$ 的目标是预测能够产生高价值状态轨迹的动作。价值模型 $v_\psi(s_\tau)$ 则反过来回归这些价值估计:

$$\max_{\phi} \mathbb{E}_{q_\theta, q_\phi} \left(\sum_{\tau=t}^{t+H} V_\lambda(s_\tau) \right), \quad (7) \quad \min_{\psi} \mathbb{E}_{q_\theta, q_\phi} \left(\sum_{\tau=t}^{t+H} \frac{1}{2} \|v_\psi(s_\tau) - V_\lambda(s_\tau)\|^2 \right). \quad (8)$$

价值模型被更新以回归这些目标, 并像通常做法一样在目标处停止梯度 (Sutton and Barto, 2018)。动作模型则利用穿过学得动力学的解析梯度来最大化价值估计。直观地说, 价值估计依赖奖励和价值预测; 这些预测依赖想象状态; 而想象状态又依赖想象动作。由于所有步骤都由神经网络实现, 我们可以通过随机反向传播 (Kingma and Welling, 2013; Rezende et al., 2014) 解析计算 $\nabla_{\phi} \mathbb{E}_{q_\theta, q_\phi} \left(\sum_{\tau=t}^{t+H} V_\lambda(s_\tau) \right)$ 。连续动作和潜在状态使用重参数化, 离散动作使用直通梯度 (Bengio et al., 2013)。学习行为时, 世界模型参数保持固定。

在可能提前终止的任务中, 世界模型还会从每个潜在状态预测折扣因子。于是, Equations 7 and 8 中各时间步会乘以预测折扣因子的累积乘积; 换言之, 如果想象轨迹更可能已经结束, 对应项的权重就会降低。

与演员批评方法的比较 使用 Reinforce 梯度的智能体 (Williams, 1992), 例如 A3C 和 PPO (Mnih et al., 2016; Schulman et al., 2017), 会使用价值基线来降低梯度方差; 而 Dreamer 会穿过价值模型反向传播。这一点类似于确定性或重参数化 actor-critic 方法 (Silver et al., 2014), 例如 DDPG 和 SAC (Lillicrap et al., 2015; Haarnoja et al., 2018)。不过, 这些方法没有利用穿过转移模型的梯度, 只最大化即时 Q 值。MVE 和 STEVE (Feinberg et al., 2018; Buckman et al., 2018) 将它们扩展为使用学得动力学的多步 Q 学习, 以提供更准确的 Q 值目标。我们预测状态价值; 由于策略梯度会穿过动力学反向传播, 这已经足以优化策略。与相关工作的更详细比较见 节 5。




图 6: 与现有方法的性能比较。Dreamer 继承了 PlaNet 的数据效率, 同时超过了最佳无模型智能体的渐近性能。在 5×10^6 个环境步后, Dreamer 在各任务上的平均得分达到 823; 作为比较, PlaNet 为 332, 顶级无模型智能体 D4PG 在 10^8 步后为 786。结果为 5 个随机种子的平均值。




图 7: Dreamer 能完成需要长时程信用分配的视觉控制任务，例如 acrobot 和 hopper。只通过动作模型或在线规划在有限视野内优化想象奖励，会产生短视行为；这类行为通常只能完成 walker 等更偏反应式的任务。图 6 汇总了所有 20 个任务的性能，训练曲线见节 D。D4PG 和 A3C 的性能曲线见 Tassa et al. (2018)。

4 学习潜在动力学

在想象中学习行为，需要世界模型具有足够好的泛化能力。本文关注潜在动力学模型：它们在紧凑的潜在空间中向前预测，便于进行长时程预测，也让智能体能够并行想象成千上万条轨迹。已有工作提出了多种面向控制的表征学习目标 (Watter et al., 2015; Jaderberg et al., 2016; Oord et al., 2018; Eslami et al., 2018)。下面讨论 Dreamer 可使用的三类表征学习方法：奖励预测、图像重建和对比估计。

奖励预测 潜在想象需要表征模型 $p(s_t | s_{t-1}, a_{t-1}, o_t)$ 、转移模型 $q(s_t | s_{t-1}, a_{t-1},)$ 和奖励模型 $q(r_t | s_t)$ ，如节 2 所述。原则上，只要学习根据动作和过去观测预测未来奖励，就可能得到这样的表征 (Oh et al., 2017; Gelada et al., 2019; Schrittwieser et al., 2019)。当数据集足够大且足够多样时，这类表征应当可以支持控制任务。但在有限数据集上，尤其是奖励稀疏时，让模型学习与奖励相关的观测信息，通常能改进世界模型 (Jaderberg et al., 2016; Gregor et al., 2019)。

重建 我们先描述 PlaNet (Hafner et al., 2018) 使用的世界模型。该模型通过重建图像来学习潜在动力学，如图 3a 所示。世界模型由以下组件构成，其中观测模型只用于提供学习信号：

$$\begin{aligned}
 \text{表征模型:} & p_{\theta}(s_t | s_{t-1}, a_{t-1}, o_t) \\
 \text{观测模型:} & q_{\theta}(o_t | s_t) \\
 \text{奖励模型:} & q_{\theta}(r_t | s_t) \\
 \text{转移模型:} & q_{\theta}(s_t | s_{t-1}, a_{t-1}).
 \end{aligned} \tag{9}$$

这些组件被联合优化，以提高变分下界 (ELBO; Jordan et al., 1999)，更一般地说，是优化变分信息瓶颈 (VIB; Tishby et al., 2000; Alemi et al., 2016)。如节 B 推导所示，该目标包含观测和奖励的重建项，以及一个 KL 正则项。

$$\begin{aligned}
 \mathcal{J}_{\text{REC}} & \doteq \mathbb{E}_p \left(\sum_t \left(\mathcal{J}_O^t + \mathcal{J}_R^t + \mathcal{J}_D^t \right) \right) + \text{const} & \mathcal{J}_O^t & \doteq \ln q(o_t | s_t) \\
 \mathcal{J}_R^t & \doteq \ln q(r_t | s_t) & \mathcal{J}_D^t & \doteq -\beta \text{KL} \left(p(s_t | s_{t-1}, a_{t-1}, o_t) \parallel q(s_t | s_{t-1}, a_{t-1}) \right).
 \end{aligned} \tag{10}$$

我们将转移模型实现为循环状态空间模型 (RSSM; Hafner et al., 2018)；表征模型把 RSSM 与作用于图像观测的卷积神经网络 (CNN; LeCun et al., 1989) 结合起来；观测模型使用转置 CNN；奖励模型则使用全连接网络。合并后的参数向量 θ 通过随机反向传播更新 (Kingma and Welling, 2013; Rezende et al., 2014)。图 5 展示了该模型的视频预测效果。模型细节见节 A 和 Hafner et al. (2018)。

对比估计 预测像素可能需要很高的模型容量。另一种做法是从图像预测状态，从而鼓励模型状态与观测之间保持互信息 (Guo et al., 2018)。这会用状态模型替代观测模型：

$$\text{状态模型:} \quad q_{\theta}(s_t | o_t). \tag{11}$$

重建目标利用了观测边缘概率为常数这一事实；改用状态模型后，需要处理状态边缘概率。如节 B 所示，可以通过噪声对比估计 (NCE; Gutmann and Hyvärinen, 2010; Oord et al., 2018) 来估计它，做法是在当前序列批次中的观测 o' 上平均状态模型。直观地说， $q(s_t | o_t)$ 让状态可以由当前图像预测，而 $\ln \sum_{o'} q(s_t | o')$ 保持状态的多样性，避免表示塌缩：

$$\mathcal{J}_{\text{NCE}} \doteq \mathbb{E} \left(\sum_t \left(\mathcal{J}_S^t + \mathcal{J}_R^t + \mathcal{J}_D^t \right) \right) \quad \mathcal{J}_S^t \doteq \ln q(s_t | o_t) - \ln \left(\sum_{o'} q(s_t | o') \right). \tag{12}$$

我们将状态模型实现为 CNN，并同样使用随机反向传播优化合并参数向量 θ 。这种目标避免了像素预测，但该下界能够高效提取的信息量有限 (McAllester and Statos, 2018)。在实验中，我们对奖励预测、图像重建和对比目标进行了经验比较，结果见图 8。

5 相关工作

已有工作通过无导数策略学习或在线规划来学习视觉控制中的潜在动力学，也有工作用多步预测增强无模型智能体，或利用 Q 值和多步奖励的解析梯度；这些方法通常面向低维任务。相比之下，Dreamer 纯粹依靠潜在想象，并通过解析梯度高效学习视觉控制中的长时程行为。

基于潜在动力学的控制 E2C (Watter et al., 2015) 和 RCE (Banijamali et al., 2017) 将图像嵌入到紧凑空间中，并在该空间内向前预测，用于求解简单任务。World Models (Ha and Schmidhuber, 2018) 以两阶段方式学习潜在动力学，并在想象中演化线性控制器。PlaNet (Hafner et al., 2018) 联合学习这些组件，并通过潜在空间中的在线规划解决视觉运动任务。SOLAR (Zhang et al., 2019) 通过潜在空间中的引导策略搜索解决机器人任务。I2A (Weber et al., 2017) 将想象轨迹交给无模型策略，而 Lee et al. (2019) 和 Gregor et al. (2019) 则学习信念表征，以加速无模型智能体。

想象的多步回报 VPN (Oh et al., 2017)、MVE (Feinberg et al., 2018) 和 STEVE (Buckman et al., 2018) 从重放缓冲区中学习动力学，用于多步 Q 学习。AlphaGo (Silver et al., 2017) 将动作和状态价值预测与规划结合起来，但假设可以访问真实动力学。同样假设可访问动力学的 POLO (Lowrey et al., 2018) 通过学习价值集成来进行探索。MuZero (Schrittwieser et al., 2019) 学习特定任务的奖励和价值模型以解决困难任务，但需要大量经验。PETS (Chua et al., 2018)、VisualMPC (Ebert et al., 2017) 和 PlaNet (Hafner et al., 2018) 使用无导数优化进行在线规划。POPLIN (Wang and Ba, 2019) 通过自我模仿改进在线规划。Piergiovanni et al. (2018) 使用潜在动力学模型，通过想象学习机器人策略。神经网络梯度规划已在小规模问题上得到验证 (Schmidhuber, 1990; Henaff et al., 2018)，但扩展到大规模任务仍有困难 (Parmas et al., 2019)。

解析价值梯度 DPG (Silver et al., 2014)、DDPG (Lillicrap et al., 2015) 和 SAC (Haarnoja et al., 2018) 利用学得的即时动作价值梯度, 通过经验回放学习策略。SVG (Heess et al., 2015) 使用单步模型预测的解析价值梯度, 降低无模型 on-policy 算法的方差。Byravan et al. (2019) 的同期工作在导航和操纵任务中使用潜在想象与确定性模型。ME-TRPO (Kurutach et al., 2018) 通过对本体感知输入的预测回报求梯度, 加速原本无模型的智能体。DistGBP (Henaff et al., 2017; 2019) 在简单任务中使用模型梯度进行在线规划。




图 8: 拟与 Dreamer。像素重建对大多数任务最有效。对比性目标解决了大约一半的任务, 而光是预测回报在我们实验中是不够的。结果表明, 今后在学习表现方面的发展, 有可能转化为改进工作性能。Dreamer. 所有任务的性能曲线包含在内节 E.

6 实验

我们在多种控制任务上对 Dreamer 进行实验评估。实验设计有两个目的: 一是将 Dreamer 与当前文献中的强方法进行比较; 二是考察它在长时程、连续动作、离散动作和提前终止任务上的表现。同时, 我们还比较了世界模型表征学习目标这一相对独立的设计选择。所有实验代码和 Dreamer 视频见 <https://danijar.com/dreamer>。

控制任务 我们在 DeepMind Control Suite (Tassa et al., 2018) 的 20 个视觉控制任务上评估 Dreamer, 如图 2 所示。这些任务包含多种挑战, 包括稀疏奖励、接触动力学和 3D 场景。我们选择的是 Tassa et al. (2018) 报告过图像输入非零性能的任务。智能体观测为 $64 \times 64 \times 3$ 图像, 动作维度从 1 到 12 不等, 奖励范围为 0 到 1, 每个 episode 持续 1000 步并具有随机初始状态。所有任务均使用固定动作重复 $R = 2$ 。此外, 我们还在一部分 Atari 游戏 (Bellemare et al., 2013) 和 DeepMind Lab 关卡 (Beattie et al., 2016) 上评估 Dreamer 对离散动作和提前终止的适用性, 详见节 C。

实现 我们的实现使用 TensorFlow Probability (Dillon et al., 2017)。每次训练运行使用一张 Nvidia V100 GPU 和 10 个 CPU 核心。在控制套件上, Dreamer 每 10^6 个环境步约需 3 小时训练时间; 作为比较, PlaNet 的在线规划约需 11 小时, D4PG 达到相近性能约需 24 小时。我们在所有连续任务上使用同一组超参数, 在所有离散任务上也使用同一组超参数, 详见节 A。除非另有说明, 世界模型均通过图像重建目标学习。

基线方法 连续控制任务中已报告的最高性能来自 D4PG (Barth-Maron et al., 2018), 这是 DDPG (Lillicrap et al., 2015) 的改进变体, 使用分布式数据收集、分布式 Q 学习、多步回报和优先经验回放。我们采用 Tassa et al. (2018) 报告的像素输入 D4PG 分数, 以及状态输入 A3C (Mnih et al., 2016) 分数。PlaNet (Hafner et al., 2018) 学习与 Dreamer 相同的世界模型, 但不学习动作模型, 而是通过在线规划选择动作; 它在数据效率上显著超过 D4PG 和 A3C。为统一实验设置, 我们使用 $R = 2$ 重新运行 PlaNet。对于 Atari, 我们展示 Castro et al. (2018) 报告的 SimPLe (Kaiser et al., 2019)、DQN (Mnih et al., 2015) 和 Rainbow (Hessel et al., 2018) 最终性能; 对于 DeepMind Lab, 则以 IMPALA (Espeholt et al., 2018) 作为参考。

性能 为评估 Dreamer 的性能，我们将其与先进强化学习智能体进行比较，结果汇总于图 6。在 5×10^6 个环境步后，Dreamer 在各任务上的平均得分为 823，超过了强无模型智能体 D4PG 在 10^8 个环境步内达到的 786 平均分。同时，Dreamer 继承了 PlaNet 的数据效率，说明学习到的世界模型有助于从少量经验中泛化。实验结果表明，利用世界模型在潜在想象中学习行为，可以超过若干基于经验回放的强方法。

长时程 为考察 Dreamer 学习长时程行为的能力，我们将它与几种从世界模型中推导行为的替代方案进行比较，并改变想象时域长度。具体来说，我们训练一个不使用价值模型的动作模型，使其最大化想象奖励，并将其与 PlaNet 的在线规划进行比较。图 4 给出了不同想象时域下的最终性能，结果表明价值模型使 Dreamer 对时域长度更鲁棒，即使在较短时域下也表现良好。节 D 展示了时域为 20 时所有任务的性能曲线：Dreamer 在 20 个任务中的 16 个上超过替代方案，其余 4 个任务持平。

表征学习 Dreamer 可以搭配任意可微动力学模型，只要该模型能根据动作和过去观测预测未来奖励。由于表征学习目标与本文算法相对独立，我们比较了节 4 中介绍的三种自然选择：像素重建、对比估计和纯奖励预测。图 8 表明，不同表征学习方法会带来明显的任务性能差异，其中像素重建在多数任务上优于对比估计。这说明，表征学习方面的改进很可能转化为 Dreamer 的任务性能提升。在我们的实验中，单独使用奖励预测并不足够；更多消融结果见论文附录。

7 结论

本文提出 Dreamer，这是一种完全通过潜在想象学习长时程行为的智能体。为此，我们提出一种 actor-critic 方法，通过学得的潜在动力学反向传播多步价值的解析梯度，从而优化参数化策略。在多种具有挑战性的图像输入连续控制任务上，Dreamer 在数据效率、计算时间和最终性能方面均超过了以往方法。我们进一步表明，Dreamer 也适用于离散动作和 episode 提前终止的任务。未来关于表示学习的研究，有望把潜在想象扩展到视觉复杂度更高的环境。

鸣谢 我们感谢西蒙·科恩布利思、本杰明·艾森巴赫、伊恩·菲舍尔、艾米·张、杰弗里·欣顿、谢恩·古、亚当·科西奥雷克、布兰登·阿莫斯、雅各布·巴克曼、卡尔文·罗和里沙布·阿加尔瓦尔，感谢我们的匿名审查员的反馈和讨论。我们感谢尤瓦尔·塔萨在控制套房中增加了四重环境。

参考文献

- A. A. Alemi, I. Fischer, J. V. Dillon, and K. Murphy. Deep variational information bottleneck. *arXiv preprint arXiv:1612.00410*, 2016.
- E. Banijamali, R. Shu, M. Ghavamzadeh, H. Bui, and A. Ghodsi. Robust locally-linear controllable embedding. *arXiv preprint arXiv:1710.05373*, 2017.
- G. Barth-Maron, M. W. Hoffman, D. Budden, W. Dabney, D. Horgan, A. Muldal, N. Heess, and T. Lillicrap. Distributed distributional deterministic policy gradients. *arXiv preprint arXiv:1804.08617*, 2018.
- C. Beattie, J. Z. Leibo, D. Teplyaev, T. Ward, M. Wainwright, H. Küttler, A. Lefrancq, S. Green, V. Valdés, A. Sadik, et al. Deepmind lab. *arXiv preprint arXiv:1612.03801*, 2016.
- M. G. Bellemare, Y. Naddaf, J. Veness, and M. Bowling. The arcade learning environment: An evaluation platform for general agents. *Journal of Artificial Intelligence Research*, 47: 253–279, 2013.
- Y. Bengio, N. Léonard, and A. Courville. Estimating or propagating gradients through stochastic neurons for conditional computation. *arXiv preprint arXiv:1308.3432*, 2013.
- J. Buckman, D. Hafner, G. Tucker, E. Brevdo, and H. Lee. Sample-efficient reinforcement learning with stochastic ensemble value expansion. In *Advances in Neural Information Processing Systems*, pages 8224–8234, 2018.
- L. Buesing, T. Weber, S. Racaniere, S. Eslami, D. Rezende, D. P. Reichert, F. Viola, F. Besse, K. Gregor, D. Hassabis, et al. Learning and querying fast generative models for reinforcement learning. *arXiv preprint arXiv:1802.03006*, 2018.
- A. Byravan, J. T. Springenberg, A. Abdolmaleki, R. Hafner, M. Neunert, T. Lampe, N. Siegel, N. Heess, and M. Riedmiller. Imagined value gradients: Model-based policy optimization with transferable latent dynamics models. *arXiv preprint arXiv:1910.04142*, 2019.
- P. S. Castro, S. Moitra, C. Gelada, S. Kumar, and M. G. Bellemare. Dopamine: A research framework for deep reinforcement learning. *arXiv preprint arXiv:1812.06110*, 2018.
- K. Chua, R. Calandra, R. McAllister, and S. Levine. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. In *Advances in Neural Information Processing Systems*, pages 4754–4765, 2018.
- D.-A. Clevert, T. Unterthiner, and S. Hochreiter. Fast and accurate deep network learning by exponential linear units (elus). *arXiv preprint arXiv:1511.07289*, 2015.
- J. V. Dillon, I. Langmore, D. Tran, E. Brevdo, S. Vasudevan, D. Moore, B. Patton, A. Alemi, M. Hoffman, and R. A. Saurous. Tensorflow distributions. *arXiv preprint arXiv:1711.10604*, 2017.
- A. Doerr, C. Daniel, M. Schiegg, D. Nguyen-Tuong, S. Schaal, M. Toussaint, and S. Trimpe. Probabilistic recurrent state-space models. *arXiv preprint arXiv:1801.10395*, 2018.
- F. Ebert, C. Finn, A. X. Lee, and S. Levine. Self-supervised visual planning with temporal skip connections. *arXiv preprint arXiv:1710.05268*, 2017.
- S. A. Eslami, D. J. Rezende, F. Besse, F. Viola, A. S. Morcos, M. Garnelo, A. Ruderman, A. A. Rusu, I. Danihelka, K. Gregor, et al. Neural scene representation and rendering. *Science*, 360(6394):1204–1210, 2018.
- L. Espeholt, H. Soyer, R. Munos, K. Simonyan, V. Mnih, T. Ward, Y. Doron, V. Firoiu, T. Harley, I. Dunning, et al. Impala: Scalable distributed deep-rl with importance weighted actor-learner architectures. *arXiv preprint arXiv:1802.01561*, 2018.

- V. Feinberg, A. Wan, I. Stoica, M. I. Jordan, J. E. Gonzalez, and S. Levine. Model-based value estimation for efficient model-free reinforcement learning. *arXiv preprint arXiv:1803.00101*, 2018.
- C. Gelada, S. Kumar, J. Buckman, O. Nachum, and M. G. Bellemare. Deepmdp: Learning continuous latent space models for representation learning. *arXiv preprint arXiv:1906.02736*, 2019.
- K. Gregor, D. J. Rezende, F. Besse, Y. Wu, H. Merzic, and A. v. d. Oord. Shaping belief states with generative environment models for rl. *arXiv preprint arXiv:1906.09237*, 2019.
- Z. D. Guo, M. G. Azar, B. Piot, B. A. Pires, T. Pohlen, and R. Munos. Neural predictive belief representations. *arXiv preprint arXiv:1811.06407*, 2018.
- M. Gutmann and A. Hyvärinen. Noise-contrastive estimation: A new estimation principle for unnormalized statistical models. In *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, pages 297–304, 2010.
- D. Ha and J. Schmidhuber. World models. *arXiv preprint arXiv:1803.10122*, 2018.
- T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. *arXiv preprint arXiv:1801.01290*, 2018.
- D. Hafner, T. Lillicrap, I. Fischer, R. Villegas, D. Ha, H. Lee, and J. Davidson. Learning latent dynamics for planning from pixels. *arXiv preprint arXiv:1811.04551*, 2018.
- N. Heess, G. Wayne, D. Silver, T. Lillicrap, T. Erez, and Y. Tassa. Learning continuous control policies by stochastic value gradients. In *Advances in Neural Information Processing Systems*, pages 2944–2952, 2015.
- M. Henaff, W. F. Whitney, and Y. LeCun. Model-based planning in discrete action spaces. *CoRR*, abs/1705.07177, 2017.
- M. Henaff, W. F. Whitney, and Y. LeCun. Model-based planning with discrete and continuous actions. *arXiv preprint arXiv:1705.07177*, 2018.
- M. Henaff, A. Canziani, and Y. LeCun. Model-predictive policy learning with uncertainty regularization for driving in dense traffic. *arXiv preprint arXiv:1901.02705*, 2019.
- M. Hessel, J. Modayil, H. Van Hasselt, T. Schaul, G. Ostrovski, W. Dabney, D. Horgan, B. Piot, M. Azar, and D. Silver. Rainbow: Combining improvements in deep reinforcement learning. In *Thirty-Second AAAI Conference on Artificial Intelligence*, 2018.
- M. Jaderberg, V. Mnih, W. M. Czarnecki, T. Schaul, J. Z. Leibo, D. Silver, and K. Kavukcuoglu. Reinforcement learning with unsupervised auxiliary tasks. *arXiv preprint arXiv:1611.05397*, 2016.
- M. I. Jordan, Z. Ghahramani, T. S. Jaakkola, and L. K. Saul. An introduction to variational methods for graphical models. *Machine learning*, 37(2):183–233, 1999.
- L. Kaiser, M. Babaeizadeh, P. Milos, B. Osinski, R. H. Campbell, K. Czechowski, D. Erhan, C. Finn, P. Kozakowski, S. Levine, et al. Model-based reinforcement learning for atari. *arXiv preprint arXiv:1903.00374*, 2019.
- R. E. Kalman. A new approach to linear filtering and prediction problems. *Journal of basic Engineering*, 82(1):35–45, 1960.
- M. Karl, M. Soelch, J. Bayer, and P. van der Smagt. Deep variational bayes filters: Unsupervised learning of state space models from raw data. *arXiv preprint arXiv:1605.06432*, 2016.
- D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

- D. P. Kingma and M. Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- R. G. Krishnan, U. Shalit, and D. Sontag. Deep kalman filters. *arXiv preprint arXiv:1511.05121*, 2015.
- T. Kurutach, I. Clavera, Y. Duan, A. Tamar, and P. Abbeel. Model-ensemble trust-region policy optimization. *arXiv preprint arXiv:1802.10592*, 2018.
- Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel. Backpropagation applied to handwritten zip code recognition. *Neural computation*, 1(4):541–551, 1989.
- A. X. Lee, A. Nagabandi, P. Abbeel, and S. Levine. Stochastic latent actor-critic: Deep reinforcement learning with a latent variable model. *arXiv preprint arXiv:1907.00953*, 2019.
- T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra. Continuous control with deep reinforcement learning. *arXiv preprint arXiv:1509.02971*, 2015.
- K. Lowrey, A. Rajeswaran, S. Kakade, E. Todorov, and I. Mordatch. Plan online, learn offline: Efficient learning and exploration via model-based control. *arXiv preprint arXiv:1811.01848*, 2018.
- M. C. Machado, M. G. Bellemare, E. Talvitie, J. Veness, M. Hausknecht, and M. Bowling. Revisiting the arcade learning environment: Evaluation protocols and open problems for general agents. *Journal of Artificial Intelligence Research*, 61:523–562, 2018.
- D. McAllester and K. Statos. Formal limitations on the measurement of mutual information. *arXiv preprint arXiv:1811.04251*, 2018.
- V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529, 2015.
- V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver, and K. Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *International Conference on Machine Learning*, pages 1928–1937, 2016.
- J. Oh, S. Singh, and H. Lee. Value prediction network. In *Advances in Neural Information Processing Systems*, pages 6118–6128, 2017.
- A. v. d. Oord, Y. Li, and O. Vinyals. Representation learning with contrastive predictive coding. *arXiv preprint arXiv:1807.03748*, 2018.
- P. Parmas, C. E. Rasmussen, J. Peters, and K. Doya. PIPPS: Flexible model-based policy search robust to the curse of chaos. *arXiv preprint arXiv:1902.01240*, 2019.
- A. Piergiovanni, A. Wu, and M. S. Ryoo. Learning real-world robot policies by dreaming. *arXiv preprint arXiv:1805.07813*, 2018.
- B. Poole, S. Ozair, A. v. d. Oord, A. A. Alemi, and G. Tucker. On variational bounds of mutual information. *arXiv preprint arXiv:1905.06922*, 2019.
- D. J. Rezende, S. Mohamed, and D. Wierstra. Stochastic backpropagation and approximate inference in deep generative models. *arXiv preprint arXiv:1401.4082*, 2014.
- J. Schmidhuber. Making the world differentiable: On using self-supervised fully recurrent neural networks for dynamic reinforcement learning and planning in non-stationary environments. 1990.
- J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, et al. Mastering atari, go, chess and shogi by planning with a learned model. *arXiv preprint arXiv:1911.08265*, 2019.

- J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra, and M. Riedmiller. Deterministic policy gradient algorithms. In *Proceedings of the 31st International Conference on Machine Learning*, 2014.
- D. Silver, J. Schrittwieser, K. Simonyan, I. Antonoglou, A. Huang, A. Guez, T. Hubert, L. Baker, M. Lai, A. Bolton, et al. Mastering the game of go without human knowledge. *Nature*, 550(7676):354, 2017.
- A. Srinivas, A. Jabri, P. Abbeel, S. Levine, and C. Finn. Universal planning networks. *arXiv preprint arXiv:1804.00645*, 2018.
- R. S. Sutton. Dyna, an integrated architecture for learning, planning, and reacting. *ACM SIGART Bulletin*, 2(4):160–163, 1991.
- R. S. Sutton and A. G. Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- Y. Tassa, Y. Doron, A. Muldal, T. Erez, Y. Li, D. d. L. Casas, D. Budden, A. Abdolmaleki, J. Merel, A. Lefrancq, et al. Deepmind control suite. *arXiv preprint arXiv:1801.00690*, 2018.
- N. Tishby, F. C. Pereira, and W. Bialek. The information bottleneck method. *arXiv preprint physics/0004057*, 2000.
- T. Wang and J. Ba. Exploring model-based planning with policy networks. *arXiv preprint arXiv:1906.08649*, 2019.
- T. Wang, X. Bao, I. Clavera, J. Hoang, Y. Wen, E. Langlois, S. Zhang, G. Zhang, P. Abbeel, and J. Ba. Benchmarking model-based reinforcement learning. *CoRR*, abs/1907.02057, 2019.
- M. Watter, J. Springenberg, J. Boedecker, and M. Riedmiller. Embed to control: A locally linear latent dynamics model for control from raw images. In *Advances in neural information processing systems*, pages 2746–2754, 2015.
- T. Weber, S. Racanière, D. P. Reichert, L. Buesing, A. Guez, D. J. Rezende, A. P. Badia, O. Vinyals, N. Heess, Y. Li, et al. Imagination-augmented agents for deep reinforcement learning. *arXiv preprint arXiv:1707.06203*, 2017.
- R. J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine learning*, 8(3-4):229–256, 1992.
- M. Zhang, S. Vikram, L. Smith, P. Abbeel, M. Johnson, and S. Levine. Solar: deep structured representations for model-based reinforcement learning. In *International Conference on Machine Learning*, 2019.

A 超参数

模型组件 我们使用 Ha and Schmidhuber (2018) 的卷积编码器和解码器网络, 使用 Hafner et al. (2018) 的 RSSM, 并将其他函数实现为 3 层全连接网络, 每层大小为 300, 激活函数为 ELU (Clevert et al., 2015)。潜在空间中的分布为 30 维对角高斯分布。动作模型输出经过 tanh 的均值, 并将其放大 5 倍, 同时输出用于 Normal 分布的 softplus 标准差; 随后该 Normal 分布再经过 tanh 变换 (Haarnoja et al., 2018)。这一缩放因子使智能体能够让动作分布达到饱和。

学习更新 我们抽取批量大小为 50、序列长度为 50 的数据批次, 使用 Adam (Kingma and Ba, 2014) 训练世界模型、价值模型和动作模型; 三者学习率分别为 6×10^{-4} 、 8×10^{-5} 和 8×10^{-5} , 并将超过 100 的梯度范数缩小。我们不缩放 KL 正则项 ($\beta = 1$), 但像 PlaNet 一样将其下限裁剪为 3 个 free nats。想象时域为 $H = 15$, 同一批想象轨迹同时用于更新动作模型和价值模型。 V_λ 目标使用 $\gamma = 0.99$ 和 $\lambda = 0.95$ 计算。实验中, 我们没有发现模型学习需要 latent overshooting, 动作模型需要熵奖励, 或价值模型需要目标网络。

环境交互 数据集初始化为 $S = 5$ 个使用随机动作收集的 episode。之后, 我们交替执行 100 个训练步和 1 个数据收集 episode; 收集数据时执行动作模型预测的众数动作, 并加入 Normal(0, 0.3) 探索噪声。不同于 Hafner et al. (2018) 和 Lee et al. (2019) 为每个环境手动选择动作重复次数, 我们在所有环境中固定为 2。图 12 给出了不同动作重复值下的鲁棒性评估。

离散控制 在 Atari 游戏和 DeepMind Lab 关卡实验中, 动作模型预测 categorical 分布的 logits。在潜在想象中, 我们对采样步骤使用直通梯度。动作噪声采用 epsilon-greedy, 其中 ϵ 在前 200,000 个梯度步内从 0.4 线性退火到 0.1。考虑到这些任务更复杂, 我们使用 $H = 10$ 的想象时域, 将 KL 正则项缩放为 $\beta = 0.1$, 并用 tanh 对奖励进行有界化。我们还使用二分类器从潜在状态预测折扣因子, 该分类器用 0 和 γ 的软标签训练。

B 推导

我们为潜在动力学模型定义信息瓶颈目标 (Tishby et al., 2000):

$$\max \mathbb{I}(s_{1:T}; (o_{1:T}, r_{1:T}) \mid a_{1:T}) - \beta \mathbb{I}(s_{1:T}, i_{1:T} \mid a_{1:T}), \quad (13)$$

其中 β 是标量, i_t 是数据集索引, 用于确定观测 $p(o_t \mid i_t) \doteq \delta(o_t - \bar{o}_t)$, 与 Alemi et al. (2016) 中的设定一致。

最大化该目标会促使模型状态预测观测和奖励序列, 同时限制每个时间步可提取的信息量。这样, 模型在重建每张图像时会尽可能依赖先前时间步提取到的信息, 只在必要时从当前图像中读取额外信息。因此, 信息正则项鼓励模型学习长期依赖关系。

对于生成式目标, 我们利用 KL 散度的非负性为第一项构造下界, 并去掉边缘数据概率, 因为它不依赖于表征模型:

$$\begin{aligned} & \mathbb{I}(s_{1:T}; (o_{1:T}, r_{1:T}) \mid a_{1:T}) \\ &= \mathbb{E}_{p(o_{1:T}, r_{1:T}, s_{1:T}, a_{1:T})} \left(\sum_t \ln p(o_{1:T}, r_{1:T} \mid s_{1:T}, a_{1:T}) - \underbrace{\ln p(o_{1:T}, r_{1:T} \mid a_{1:T})}_{\text{const}} \right) \\ &\stackrel{\pm}{=} \mathbb{E} \left(\sum_t \ln p(o_{1:T}, r_{1:T} \mid s_{1:T}, a_{1:T}) \right) \\ &\geq \mathbb{E} \left(\sum_t \ln p(o_{1:T}, r_{1:T} \mid s_{1:T}, a_{1:T}) \right) - \text{KL} \left(p(o_{1:T}, r_{1:T} \mid s_{1:T}, a_{1:T}) \parallel \prod_t q(o_t \mid s_t) q(r_t \mid s_t) \right) \\ &= \mathbb{E} \left(\sum_t \ln q(o_t \mid s_t) + \ln q(r_t \mid s_t) \right). \end{aligned} \quad (14)$$

对于对比目标, 我们减去变分编码器下的数据常数边缘概率, 应用 Bayes 规则, 并使用 InfoNCE 小批量下界 (Poole et al., 2019):

$$\begin{aligned} & \mathbb{E}(\ln q(o_t \mid s_t) + \ln q(r_t \mid s_t)) \\ &\stackrel{\pm}{=} \mathbb{E}(\ln q(o_t \mid s_t) - \ln q(o_t) + \ln q(r_t \mid s_t)) \\ &= \mathbb{E}(\ln q(s_t \mid o_t) - \ln q(s_t) + \ln q(r_t \mid s_t)) \\ &\geq \mathbb{E} \left(\ln q(s_t \mid o_t) - \ln \sum_{o'} q(s_t \mid o') + \ln q(r_t \mid s_t) \right). \end{aligned} \quad (15)$$

对于第二项, 我们同样利用 KL 散度的非负性得到一个上界:

$$\begin{aligned} & \mathbb{I}(s_{1:T}; i_{1:T} \mid a_{1:T}) \\ &= \mathbb{E}_{p(o_{1:T}, r_{1:T}, s_{1:T}, a_{1:T}, i_{1:T})} \left(\sum_t \ln p(s_t \mid s_{t-1}, a_{t-1}, i_t) - \ln p(s_t \mid s_{t-1}, a_{t-1}) \right) \\ &= \mathbb{E} \left(\sum_t \ln p(s_t \mid s_{t-1}, a_{t-1}, o_t) - \ln p(s_t \mid s_{t-1}, a_{t-1}) \right) \\ &\leq \mathbb{E} \left(\sum_t \ln p(s_t \mid s_{t-1}, a_{t-1}, o_t) - \ln q(s_t \mid s_{t-1}, a_{t-1}) \right) \\ &= \mathbb{E} \left(\sum_t \text{KL} \left(p(s_t \mid s_{t-1}, a_{t-1}, o_t) \parallel q(s_t \mid s_{t-1}, a_{t-1}) \right) \right). \end{aligned} \quad (16)$$

由此得到原目标的下界。

C 离散控制

我们在 Atari 套件 (Bellemare et al., 2013) 和 DeepMind Lab (Beattie et al., 2016) 中选取一部分离散动作任务来评估 Dreamer。尽管完全通过世界模型学习的智能体在这些领域尚未具备竞争力 (Kaiser et al., 2019)，这些任务仍提供了具有视觉复杂性、稀疏奖励和提前终止特性的多样化测试平台。智能体观测 $64 \times 64 \times 3$ 图像，并从 3 到 18 个动作中选择其一。对于 Atari，我们遵循 Machado et al. (2018) 的 sticky actions 评估协议。相关实验见 图 9。




图 9: 性能 Dreamer 在有离散动作和提前终止的环境中。Dreamer 学习此子集的成功行为 Atari 游戏和 DMLab 的对象收藏级别。我们强调为这些环境学习表现，以此作为未来工作的方向，从而能够使所有角色都具有竞争力。Atari 游戏和 DMLab 级别 Dreamer.

D 行为学习




图 10: 在 DeepMind Control Suite 连续控制任务上比较不同动作选择方案，输入均为像素。曲线表示环境步数上的平均得分，阴影区域表示 5 个随机种子的标准差。我们比较了在想象中同时学习动作和价值的 Dreamer、只在想象中学习动作的变体，以及不学习策略而通过在线规划选择动作的 PlaNet。基线包括强无模型算法 D4PG、常用 A3C 智能体和混合方法 SLAC。

E 表征学习




图 11: 代表制学习方法比较 Dreamer。线条显示平均分数, 阴影区域显示 5 种种子的标准偏差。我们比较生成图像和奖励, 产生奖励, 利用对比损失来了解图像, 并且只预测奖励。图像重建为大多数任务提供了最好的学习信号, 其次是对比性目标。在我们的实验中, 纯粹学习奖励是不够的, 可能需要更多的经验。

F 动作重复




图 12: 强健性 Dreamer 增强的学习方法可以对这个超参数敏感, 在环境控制频率下学习动态模型时可以放大。Dreamer 重复的动作量不同。区域显示一个标准偏差, 横跨两个种子。我们在本次实验中使用了之前的超参数设置。我们发现这个值 $R = 2$ 最佳工作跨任务。

G 连续控制分数

	A3C	D4PG	PlaNet ¹	Dreamer
输入模态	本体感知	像素	像素	像素
环境步数	10^8	10^8	5×10^6	5×10^6
Acrobot Swingup	41.90	91.70	3.21	365.26
Cartpole Balance	951.60	992.80	452.56	979.56
Cartpole Balance Sparse	857.40	1000.00	164.74	941.84
Cartpole Swingup	558.40	862.00	312.56	833.66
Cartpole Swingup Sparse	179.80	482.00	0.64	812.22
Cheetah Run	213.90	523.80	496.12	894.56
Cup Catch	104.70	980.50	455.98	962.48
Finger Spin	129.40	985.70	495.25	498.88
Finger Turn Easy	167.30	971.40	451.22	825.86
Finger Turn Hard	88.70	966.00	312.55	891.38
Hopper Hop	0.50	242.00	0.37	368.97
Hopper Stand	27.90	929.90	5.96	923.72
Pendulum Swingup	48.60	680.90	3.27	833.00
Quadruped Run	—	—	280.45	888.39
Quadruped Walk	—	—	238.90	931.61
Reacher Easy	95.60	967.40	468.50	935.08
Reacher Hard	39.70	957.10	187.02	817.05
Walker Run	191.80	567.20	626.25	824.67
Walker Stand	378.40	985.20	759.19	977.99
Walker Walk	311.00	968.30	944.70	961.67
平均数	243.70	786.32	332.97	823.39

¹我们使用固定动作重复 $R = 2$ 重新运行 PlaNet, 因此得分与 Hafner et al. (2018) 报告的数值不同。