

Learning Latent Dynamics for Planning from Pixels

Danijar Hafner^{1,2} Timothy Lillicrap³ Ian Fischer⁴ Ruben Villegas^{1,5}
David Ha¹ Honglak Lee¹ James Davidson¹

摘要

在环境动力学已知的控制任务中，规划方法已经非常有效。要在未知环境中使用规划，智能体必须通过与环境交互来学习动力学。然而，学习一个精度足以支持规划的 dynamics 模型，尤其是在基于图像的任务中，长期以来都很困难。本文提出 Deep Planning Network (PlaNet)，这是一种纯模型智能体：它从图像中学习环境动力学，并在潜在空间中通过快速在线规划选择动作。为了取得高性能，dynamics 模型需要在多个时间步上准确预测未来奖励。为此，我们使用同时包含确定性和随机转移成分的潜在 dynamics 模型，并提出一个称为潜在过冲的多步变分推断目标。仅依靠像素观测，本文智能体即可解决包含接触动力学、部分可观测性和稀疏奖励的连续控制任务；这些任务比此前使用学习模型进行规划所解决的任务更难。PlaNet 使用的回合数显著更少，最终性能接近、在部分情况下甚至超过了强无模型算法。

1. 引言

对于动力学已知的决策问题，规划是一种自然且有效的方法，典型例子包括博弈和模拟机器人控制 (Tassa et al., 2012; Silver et al., 2017; Moravčík et al., 2017)。在未知环境中进行规划时，智能体必须从经验中学习环境动力学。如何学到足以支撑规划的准确 dynamics 模型，一直是一个难题。主要困难包括模型误差、多步预测中的误差累积、无法刻画多个可能未来，以及在训练分布之外给出过度自信的预测。

与无模型强化学习相比，使用学习到的模型进行规划有几个优势。首先，基于模型的规划能够利用更丰富的训练信号，不需要通过 Bellman 备份传播奖励，因此通常更具数据效率。其次，规划可以通过增加动作搜索的计算预算来提升性能，这一点已由 Silver et al.

(2017) 展示。最后，学习到的动力学模型可以与具体任务解耦，因此有机会迁移到同一环境中的其他任务。


近期工作已经能在简单低维环境中学习动力学模型 (Deisenroth & Rasmussen, 2011; Gal et al., 2016; Amos et al., 2018; Chua et al., 2018; Henaff et al., 2018)。不过，这些方法通常假设可以访问环境的底层状态和奖励函数，而实际应用中未必具备这样的条件。在高维环境中，我们希望在紧凑的潜在空间中学习动力学，从而支持快速规划。此前，潜在模型的成功主要局限于较简单的任务，例如从稠密奖励中学习平衡 cartpole 或控制双连杆机械臂 (Watter et al., 2015; Banijamali et al., 2017)。

本文提出 Deep Planning Network (PlaNet)，一种基于模型的智能体。它从像素中学习环境动力学，并在紧凑的潜在空间中通过在线规划选择动作。为了学习动力学，我们使用同时包含随机成分和确定性成分的转移模型；此外，还实验了一种鼓励多步预测的广义变分目标。PlaNet 能够从像素输入解决连续控制任务，这些任务比此前通过学习模型进行规划所解决的任务更具挑战性。

本文的主要贡献如下：

- **Planning in latent spaces** 我们通过学习动力学模型并在其潜在空间中高效规划，解决了图 1 所示的多种 DeepMind Control Suite 任务。最终性能上，我们的智能体显著优于无模型 A3C，并在部分任务上超过 D4PG；同时，平均只需要约 1/200 的环境交互量，计算时间相近。
- **Recurrent state space model** 我们设计了一种同时包含确定性成分和随机成分的潜在动力学模型 (Buesing et al., 2018; Chung et al., 2015)。实验表明，这两个组成部分对取得较高规划性能都很关键。
- **Latent overshooting** 我们将标准变分下界推广到多步预测。该目标只使用潜在空间中的项，因此可以作为高效正则项改进长期预测，并与任意潜在序列模型兼容。

¹Google Brain²University of Toronto³DeepMind⁴Google Research⁵University of Michigan. 通讯作者: Danijar Hafner <mail@danijar.com>。



(a) Cartpole (b) Reacher (c) Cheetah (d) Finger (e) Cup (f) Walker

图 1: 实验中使用的基于图像的控制域。图像展示的是缩放到 $64 \times 64 \times 3$ 像素之前的智能体观测。(a) Cartpole swingup 任务使用固定相机, 因此小车可能移出视野。(b) Reacher 任务只有稀疏奖励。(c) Cheetah running 任务包含接触动力学和更多关节。(d) Finger spinning 任务包含手指与物体之间的接触。(e) Cup 任务奖励稀疏, 只有接住球后才给出奖励。(f) Walker 任务要求机器人在倒地后保持平衡, 并预测与地面之间较复杂的相互作用。

算法 1: Deep Planning Network (PlaNet)

Input:

R Action repeat
 S Seed episodes
 C Collect interval
 B Batch size
 L Chunk length
 α Learning rate
 $p(s_t | s_{t-1}, a_{t-1})$ Transition model
 $p(o_t | s_t)$ Observation model
 $p(r_t | s_t)$ Reward model
 $q(s_t | o_{\leq t}, a_{< t})$ Encoder
 $p(\epsilon)$ Exploration noise

```

1 Initialize dataset  $\mathcal{D}$  with  $S$  random seed episodes.
2 Initialize model parameters  $\theta$  randomly.
3 while not converged do
    // Model fitting
4   for update step  $s = 1..C$  do
5     Draw sequence chunks
        $\{(o_t, a_t, r_t)_{t=k}^{L+k}\}_{i=1}^B \sim \mathcal{D}$  uniformly at
       random from the dataset.
6     Compute loss  $\mathcal{L}(\theta)$  from Equation 3.
7     Update model parameters
        $\theta \leftarrow \theta - \alpha \nabla_{\theta} \mathcal{L}(\theta)$ .

    // Data collection
8    $o_1 \leftarrow \text{env.reset}()$ 
9   for time step  $t = 1..\lceil \frac{T}{R} \rceil$  do
10    Infer belief over current state
        $q(s_t | o_{\leq t}, a_{< t})$  from the history.
11     $a_t \leftarrow \text{planner}(q(s_t | o_{\leq t}, a_{< t}), p)$ , see 算
       法 2 in the appendix for details.
12    Add exploration noise  $\epsilon \sim p(\epsilon)$  to the
       action.
13    for action repeat  $k = 1..R$  do
14       $r_t^k, o_{t+1}^k \leftarrow \text{env.step}(a_t)$ 
15       $r_t, o_{t+1} \leftarrow \sum_{k=1}^R r_t^k, o_{t+1}^k$ 
16   $\mathcal{D} \leftarrow \mathcal{D} \cup \{(o_t, a_t, r_t)_{t=1}^T\}$ 

```

2. 潜在空间规划

为了通过规划解决未知环境, 智能体需要从经验中学习环境动力学。PlaNet 采用迭代流程: 先用规划收集数据, 再用收集到的数据训练动力学模型。本节先给出环境记号, 并说明基于模型智能体的整体实现。这里暂且假设已有学习得到的动力学模型; 模型设计和训练目标见节 3。

问题设置 单帧图像通常不能完全揭示环境状态, 因此我们将问题建模为部分可观察马尔可夫决策过程 (POMDP)。记离散时间步为 t , 隐藏状态为 s_t , 图像观测为 o_t , 连续动作向量为 a_t , 标量奖励为 r_t , 它们服从如下随机动力学:

$$\begin{aligned}
 \text{Transition function:} \quad & s_t \sim p(s_t | s_{t-1}, a_{t-1}) \\
 \text{Observation function:} \quad & o_t \sim p(o_t | s_t) \\
 \text{Reward function:} \quad & r_t \sim p(r_t | s_t) \\
 \text{策略:} \quad & a_t \sim p(a_t | o_{\leq t}, a_{< t}),
 \end{aligned} \tag{1}$$

不失一般性, 我们假设初始状态 s_0 固定。目标是实现一个策略 $p(a_t | o_{\leq t}, a_{< t})$, 使预期累计奖励 $\mathbb{E}_p[\sum_{t=1}^T r_t]$ 最大, 其中期望同时取自环境分布和策略分布。

基于模型的规划 PlaNet 从已有回合中学习转移模型 $p(s_t | s_{t-1}, a_{t-1})$ 、观测模型 $p(o_t | s_t)$ 和奖励模型 $p(r_t | s_t)$ (这里用斜体字母表示模型分布, 用直立字母表示真实动力学)。观测模型提供丰富的训练信号, 但不参与规划。我们还学习编码器 $q(s_t | o_{\leq t}, a_{< t})$, 通过过滤从历史中推断当前隐藏状态的近似信念。基于这些组成部分, 我们将策略实现为搜索未来最优动作序列的规划算法。模型预测控制 (MPC; Richards, 2005) 使智能体能够根据新的观测调整计划, 因此每个时间步都会重新规划。与无模型和混合强化学习算法不同, 我们不使用策略网络或价值网络。

经验收集 由于智能体一开始可能无法访问环境的所有区域, 我们需要不断收集新经验并改进动力学模型。如算法 1 所示, 我们从 S 个由随机动作收集的种子回合开始训练模型, 之后每经过 C 个更新步骤就向数据集加入一个新回合。收集回合时, 我们在动作上加

入小幅高斯探索噪声。为缩短规划视野，并向模型提供更清晰的学习信号，我们像强化学习中的常见做法一样，将每个动作重复 R 次 (Mnih et al., 2015; 2016)。

规划算法 我们使用交叉熵方法 (CEM; Rubinstein, 1997; Chua et al., 2018) 在学习模型下搜索最优动作序列, 流程见算法 2。选择该算法是因为它足够稳健, 并且在使用真实动力学规划时能解决本文考虑的所有任务。CEM 是一种基于种群的优化算法, 通过估计动作序列上的分布来最大化目标。附录中的算法 2 给出了细节: 我们初始化一个随时间变化的对角高斯信念, 用来表示最优动作序列 $a_{t:t+H} \sim \text{Normal}(\mu_{t:t+H}, \sigma_{t:t+H}^2 \mathbb{I})$, 其中 t 为智能体当前时间步, H 为规划视野长度。从零均值、单位方差开始, 我们反复采样 J 个候选动作序列, 在模型下评估它们, 并用排名前 K 的序列重新拟合该信念。经过 I 次迭代后, 规划器返回当前时间步信念的均值 μ_t 。需要注意的是, 在接收下一次观测后, 动作序列的信念会重新从零均值和单位方差开始, 以避免陷入局部最优。

为了在学习模型下评估候选动作序列, 我们从当前状态信念出发采样一条状态轨迹, 并累加沿该序列预测的平均奖励。由于优化器本身基于种群, 我们发现每个动作序列只考虑一条轨迹已经足够, 从而可以把计算预算用于评估更多不同的序列。奖励被建模为潜在状态的函数, 因此规划器可以完全在潜在空间中运行, 无需生成图像; 这使得大批量动作序列的评估速度更快。下一节介绍规划器所使用的潜在动力学模型。

3. 循环状态空间模型

为了进行规划, 智能体在每个时间步都需要评估成千上万条候选动作序列。因此, 我们使用循环状态空间模型 (RSSM), 它可以完全在潜在空间中向前预测, 类似于近期提出的若干模型 (Karl et al., 2016; Buesing et al., 2018; Doerr et al., 2018)。该模型可以看作非线性 Kalman 滤波器或序列 VAE。本文不对既有架构做大规模比较, 而是强调两个对未来动力学模型设计有参考价值的发现: 实验表明, 转移模型中的随机路径和确定性路径都是成功规划所需的关键因素。本节先简要回顾潜在状态空间模型, 再描述本文使用的动力学模型。

潜在动力学 我们考虑序列 $\{o_t, a_t, r_t\}_{t=1}^T$, 其中 t 为离散时间步, o_t 为图像观测, a_t 为连续动作向量, r_t 为标量奖励。典型潜在状态空间模型如图 2b 所示, 其结构类似于部分可观测马尔可夫决策过程。它使用隐藏状态序列 $\{s_t\}_{t=1}^T$ 定义图像和奖励的生成过程:

$$\begin{aligned} \text{转移模型:} & s_t \sim p(s_t | s_{t-1}, a_{t-1}) \\ \text{观测模型:} & o_t \sim p(o_t | s_t) \\ \text{奖励模型:} & r_t \sim p(r_t | s_t), \end{aligned} \quad (2)$$

不失一般性, 我们假设初始状态 s_0 固定。转移模型为高斯分布, 其均值和方差由前馈神经网络参数化; 观

测模型为高斯分布, 均值由反卷积神经网络参数化, 协方差为单位矩阵; 奖励模型是标量高斯分布, 其均值由前馈神经网络参数化, 方差为 1。注意, 在单位方差高斯分布下, log-likelihood 与均方误差只差一个常数。

变分编码器 由于模型是非线性的, 参数学习所需的状态后验无法直接计算。因此, 我们使用编码器 $q(s_{1:T} | o_{1:T}, a_{1:T}) = \prod_{t=1}^T q(s_t | s_{t-1}, a_{t-1}, o_t)$, 根据过去观测和动作推断近似状态后验。其中, $q(s_t | s_{t-1}, a_{t-1}, o_t)$ 是对角高斯分布, 均值和方差先由卷积神经网络、再由前馈神经网络参数化。我们使用以过去观测为条件的 filtering posterior, 因为最终目标是在规划中使用该模型; 训练时也可以使用完整的 smoothing posterior (Babaeizadeh et al., 2017; Gregor & Besse, 2018)。

训练目标 借助编码器, 我们可以构造数据对数似然的变分下界。为简洁起见, 下面只写出观测预测的损失; 奖励预测的损失可按同样方式得到。由 Jensen 不等式得到的变分下界为:

$$\begin{aligned} \ln p(o_{1:T} | a_{1:T}) & \triangleq \ln \int \prod_t p(s_t | s_{t-1}, a_{t-1}) p(o_t | s_t) ds_{1:T} \\ & \geq \sum_{t=1}^T \left(\underbrace{\mathbb{E}_{q(s_t | o_{\leq t}, a_{\leq t})} [\ln p(o_t | s_t)]}_{\text{reconstruction}} \leftarrow \right. \\ & \quad \left. - \underbrace{\mathbb{E} [\text{KL}[q(s_t | o_{\leq t}, a_{\leq t}) \| p(s_t | s_{t-1}, a_{t-1})]]}_{\text{complexity}} \right). \end{aligned} \quad (3)$$

推导见附录中的 Equation 8。用一个重参数化样本估计外层期望, 可以得到适用于非线性潜变量模型推断和学习的高效目标, 并可通过梯度上升优化 (Kingma & Welling, 2013; Rezende et al., 2014; Krishnan et al., 2017)。

确定性路径 尽管纯随机转移具有较强的表达能力, 但它让转移模型很难在多个时间步内稳定地记住信息。理论上, 模型可以把某些状态分量的方差学为零; 实际优化过程却未必能找到这样的解。因此, 我们引入确定性激活向量序列 $\{h_t\}_{t=1}^T$, 使模型不仅能依赖上一个状态, 还能以确定性方式访问此前的状态信息 (Chung et al., 2015; Buesing et al., 2018)。本文采用的模型如图 2c 所示, 称为循环状态空间模型 (RSSM):

$$\begin{aligned} \text{确定性状态模型:} & h_t = f(h_{t-1}, s_{t-1}, a_{t-1}) \\ \text{随机状态模型:} & s_t \sim p(s_t | h_t) \\ \text{观测模型:} & o_t \sim p(o_t | h_t, s_t) \\ \text{奖励模型:} & r_t \sim p(r_t | h_t, s_t), \end{aligned} \quad (4)$$

其中 $f(h_{t-1}, s_{t-1}, a_{t-1})$ 由循环神经网络 (RNN) 实现。直观地看, 该模型把状态分为随机部分 s_t 和确定性部分 h_t ; 二者通过 RNN 依赖前一时间步的随机和确定性成分。我们使用编码器 $q(s_{1:T} | o_{1:T}, a_{1:T}) = \prod_{t=1}^T q(s_t | h_t, o_t)$ 来参数化近似状态后验。需要强调的是, 观测中的所有信息都必须经过编码器的采样步骤, 以避免从输入到重建之间形成确定性捷径。




图 2: 潜在动力学模型设计。在该示例中, 模型观测前两个时间步并预测第三个时间步。圆形表示随机变量, 方形表示确定性变量; 实线表示生成过程, 虚线表示推断模型。(a) 循环神经网络中的转移完全是确定性的, 因此模型难以捕捉多个可能未来, 规划器也更容易利用模型误差。(b) 状态空间模型中的转移完全是随机的, 因此难以在多个时间步中记住信息。(c) 我们将状态划分为随机部分和确定性部分, 使模型能够更稳健地学习预测多种未来。

在下一节中, 我们确定了潜在序列模型标准目标的局限性, 并提议对其进行概括, 以改进长期预测。

4. 潜在过冲

上一节推导了潜在序列模型中用于学习和推断的标准变分下界 (Equation 3)。如图 3a 所示, 该目标由观测重建项和近似后验的 KL 散度正则项组成。它的局限在于, 转移函数 $p(s_t | s_{t-1}, a_{t-1})$ 的随机路径只通过单步预测的 KL 散度项接受训练: 梯度会经过 $p(s_t | s_{t-1}, a_{t-1})$ 直接传入 $q(s_{t-1})$, 但不会穿过由多个 $p(s_t | s_{t-1}, a_{t-1})$ 串联而成的链条。本节将该变分下界推广为潜在过冲, 在潜在空间中训练所有多步预测。我们发现, 若干动力学模型能从潜在过冲中受益, 不过最终智能体使用的 RSSM 模型并不依赖这一项 (见节 D)。

能力有限 如果模型能够学到完美的单步预测, 它自然也能给出完美的多步预测, 这时上述问题并不存在。但实际模型容量有限, 分布族也受限; 只把模型训练到单步预测收敛, 通常并不等价于得到最适合多步预测的模型。规划需要准确的多步预测。受 Amos et al. (2018) 以及更早相关思想 (Krishnan et al., 2015; Lamb et al., 2016; Chiappa et al., 2017) 启发, 我们在所有距离的多步预测上训练模型。这里将这一思路用于潜在序列模型, 说明只在潜在空间中加入损失即可改进多步预测, 而不必额外生成图像。

多步预测 我们先把标准变分下界 (Equation 3) 从单步预测推广到固定距离 d 的多步预测。为简化记号, 此处省略条件中的动作; 每个关于 s_t 的分布都以 $a_{<t}$ 为条件。多步预测通过反复应用转移模型并积掉中间状态得到:

$$p(s_t | s_{t-d}) \triangleq \int \prod_{\tau=t-d+1}^t p(s_\tau | s_{\tau-1}) ds_{t-d+1:t-1} \quad (5)$$

$$= \mathbb{E}_{p(s_{t-1}|s_{t-d})} [p(s_t | s_{t-1})].$$

当 $d = 1$ 时, 上式退化为原模型中的单步转移。基于这一定义, 我们将 Equation 3 推广为多步预测分布 p_d 上的变分下界:

$$\begin{aligned} \ln p_d(o_{1:T}) &\triangleq \ln \int \prod_{t=1}^T p(s_t | s_{t-d}) p(o_t | s_t) ds_{1:T} \\ &\geq \sum_{t=1}^T \left(\underbrace{\mathbb{E}_{q(s_t|o_{\leq t})} [\ln p(o_t | s_t)]}_{\text{reconstruction}} \leftarrow \right. \\ &\quad \left. - \underbrace{\mathbb{E} [\text{KL}[q(s_t | o_{\leq t}) \| p(s_t | s_{t-1})]]}_{\text{multi-step prediction}} \right). \end{aligned} \quad (6)$$

推导见附录中的 Equation 9。最大化该目标会训练多步预测分布; 这也对应规划时的实际情形, 即模型必须在无法访问所有先前观测的条件下进行预测。

我们进一步猜想, 基于数据处理不等式, Equation 6 也是 $\ln p(o_{1:T})$ 的下界。由于潜在状态序列满足 Markov 性质, 对于 $d \geq 1$ 有 $I(s_t; s_{t-d}) \leq I(s_t; s_{t-1})$, 因此 $\mathbb{E}[\ln p_d(o_{1:T})] \leq \mathbb{E}[\ln p(o_{1:T})]$ 。也就是说, 在数据集期望意义下, 多步预测分布上的每个下界也对应单步预测分布上的一个下界。细节见附录中的 Equation 10。下一段将放宽单个 p_d 只能训练某一固定距离预测的限制, 并得到最终目标。

潜在过冲 上面引入的是固定距离 d 的预测下界。但在规划中, 模型需要在整个规划时域内保持多步预测准确, 而不能只针对某个固定距离优化。为此, 我们引入潜在过冲: 它把标准变分下界 (Equation 3) 推广为在所有距离 $1 \leq d \leq D$ 的多步预测上训练模型的目标:

$$\begin{aligned} \frac{1}{D} \sum_{d=1}^D \ln p_d(o_{1:T}) &\geq \sum_{t=1}^T \left(\underbrace{\mathbb{E}_{q(s_t|o_{\leq t})} [\ln p(o_t | s_t)]}_{\text{reconstruction}} \leftarrow \right. \\ &\quad \left. - \underbrace{\frac{1}{D} \sum_{d=1}^D \beta_d \mathbb{E} [\text{KL}[q(s_t | o_{\leq t}) \| p(s_t | s_{t-1})]]}_{\text{latent overshooting}} \right). \end{aligned} \quad (7)$$

潜在过冲可以理解为潜在空间中的正则项, 用来鼓励单步预测与多步预测保持一致; 在数据集期望意义下,




图 3: 展开方案。标签 $s_{i|j}$ 表示时间步 i 的状态, 并以截至时间步 j 的观测为条件。指向灰色圆点的箭头表示对数似然损失项, 波浪箭头表示 KL 散度损失项。(a) 标准变分目标在每个时间步解码后验以计算重建损失, 并在对应的先验与后验之间加入 KL 项, 从而训练单步预测的转移函数。(b) 观测过冲 (Amos et al., 2018) 会解码所有多步预测, 以施加额外重建损失; 在图像域中, 这通常代价过高。(c) 潜在过冲预测所有多步先验, 并在潜在空间中使这些状态信念接近相应后验, 从而鼓励准确的多步预测。

二者应当等价。我们引入权重因子 $\{\beta_d\}_{d=1}^D$, 其作用类似于 β -VAE (Higgins et al., 2016)。本文为简化起见将所有 $\beta_{>1}$ 设为相同值; 实际也可以分别设置, 使模型更偏向长期或短期预测。实现时, 我们会停止过冲距离 $d > 1$ 对应后验分布的梯度, 使多步预测向信息更充分的后验靠拢, 而不会反向改变这些后验。

5. 实验

我们在六个基于像素输入的连续控制任务上评估 PlaNet, 并考察智能体的多个设计维度: 动力学模型中的随机路径和确定性路径、迭代规划以及在线经验收集。超参数见附录节 A, 补充实验见节 C to E。除动作重复次数外, 所有任务使用相同的超参数。使用不到百分之一的回合数, PlaNet 的性能超过了 A3C (Mnih et al., 2016), 并达到与顶尖无模型算法 D4PG (Barth-Maron et al., 2018) 相近的水平。在单张 Nvidia V100 GPU 上, 训练时间为 10 至 20 小时 (取决于具体任务), 相较 A3C 和 D4PG 更有优势。我们的实现使用 TensorFlow Probability (Dillon et al., 2017)。代码和训练后智能体的视频可见 <https://danijar.com/planet>。

评估使用 DeepMind Control Suite 中六个基于图像的连续控制任务 (Tassa et al., 2018), 如图 1 所示。这些环境具有不同类型的挑战: cartpole swingup 需要较长规划视野, 并在小车移出视野时保持记忆; reacher 只在手臂与目标区域重合时给出稀疏奖励; finger spinning 包含手指与物体之间的接触动力学; cheetah 具有更大的状态空间和动作空间; cup 只有在接住球时才获得稀疏奖励; walker 则更难, 因为机器人必须先站起再行走, 并会出现难以预测的地面碰撞。在所有任务中, 唯一观测都是大小为 $64 \times 64 \times 3$ 像素的第三人称相机图像。

与无模型方法的比较 图 4 将 PlaNet 与 Tassa et al. (2018) 报告的非模型算法进行比较。在 100 个回合

内, PlaNet 在所有任务上都超过了从本体状态训练 100,000 个回合的策略梯度方法 A3C。经过 500 个回合后, 除 finger 任务外, 其性能接近从图像训练 100,000 个回合的 D4PG。在 cheetah run 任务上, PlaNet 相对 D4PG 的最终性能提升了 26%。数值结果见表 1, 其中还包括使用模拟器真实动力学进行 CEM 规划的性能。

模型设计 图 4 还比较了动力学模型的设计选择。我们分别训练使用循环状态空间模型 (RSSM) 的 PlaNet、纯确定性 GRU 版本 (Cho et al., 2014), 以及纯随机状态空间模型 (SSM) 版本。结果表明, 在所有任务中, 转移函数中的随机成分和确定性成分都很重要。确定性部分使模型能够跨多个时间步记忆信息; 随机部分更加关键, 缺少它时智能体无法学到有效行为。这可能是因为从智能体视角看, 初始状态的部分可观察性使任务呈现随机性。噪声也可能为规划目标增加安全裕度, 使动作序列更稳健。

智能体设计 图 5 比较了 PlaNet 的完整版本、使用随机动作而非规划来收集回合的版本, 以及每个环境步从 1000 条候选序列中直接选择最佳动作而不是通过 CEM 迭代优化计划的版本。我们观察到, 在线数据收集对所有任务都有帮助, 并且对 cartpole、finger 和 walker 任务是必要的。使用 CEM 对动作序列进行迭代搜索能提升所有任务的性能。

一个智能体所有任务 图 7 在附录中给出了单个智能体同时训练六个任务的结果。智能体不会被告知当前面对哪个任务, 必须从图像观测中自行推断。为兼容不同任务, 我们用未使用的维度填充动作空间, 并调整算法 1, 使其每经过 C 个更新步骤就为每个任务收集一个回合。超参数与主实验相同。该智能体能够解决全部任务, 但学习速度慢于分别训练的智能体。这




图 4: 将 PlaNet 与无模型算法和其他模型设计进行比较。图中展示测试性能随已收集回合数的变化。我们将使用 RSSM (节 3) 的 PlaNet 与纯确定性模型 (GRU) 和纯随机模型 (SSM) 比较。RNN 不使用潜在过冲, 因为它没有随机潜变量。曲线表示中位数, 阴影区域表示在 5 个随机种子和 10 条轨迹上得到的第 5 到第 95 百分位范围。由于奖励稀疏, 其中两个任务的阴影区域较大。

说明, 即使各域在视觉概念上差异很大, 模型仍能学会预测多个域。

6. 有关工作

以往基于模型的强化学习研究主要集中在低维状态空间中的规划 (Gal et al., 2016; Higuera et al., 2018; Henaff et al., 2018; Chua et al., 2018)、结合基于模型与无模型方法优势的混合方法 (Kalweit & Boedecker, 2017; Nagabandi et al., 2017; Weber et al., 2017; Kurutach et al., 2018; Buckman et al., 2018; Ha & Schmidhuber, 2018; Wayne et al., 2018; Igl et al., 2018; Srinivas et al., 2018), 以及不进行规划的纯视频预测 (Oh et al., 2015; Krishnan et al., 2015; Karl et al., 2016; Chiappa et al., 2017; Babaeizadeh et al., 2017; Gemici et al., 2017; Denton & Fergus, 2018; Buesing et al., 2018; Doerr et al., 2018; Gregor & Besse, 2018)。节 G 对这些相互独立的研究方向作了更详细的回顾。

真正展示出“从像素输入出发, 用学习到的动力学模型成功规划”的工作相对较少。机器人领域主要使用面向规划的视频预测模型 (Agrawal et al., 2016; Finn & Levine, 2017; Ebert et al., 2018; Zhang et al., 2018), 这些模型处理真实世界中的视觉复杂性, 并解决抓取、推动物体等简单夹爪任务。相比之下, 本文关注模拟环境, 并利用潜在空间规划扩展到更大的状态和动作空

间、更长的规划时域, 以及稀疏奖励任务。E2C (Watter et al., 2015) 和 RCE (Banijamali et al., 2017) 将图像嵌入潜在空间, 在其中学习局部线性的潜在转移, 并使用 LQR 规划动作。这些方法可以从图像中平衡模拟 cartpole、控制双连杆机械臂, 但难以继续扩展。我们放宽了这些模型的 Markov 假设, 使方法适用于部分可观测场景, 并在包含更长规划时域、接触动力学和稀疏奖励的更困难环境中给出结果。

7. 讨论

本文提出了 PlaNet, 一个基于模型的智能体。它从图像观测中学习潜在动力学模型, 并通过在潜在空间中快速规划来选择动作。为了实现准确的长时程预测, 我们设计了同时包含随机路径和确定性路径的模型。实验表明, 该智能体能够仅凭图像观测完成多个连续控制任务, 性能接近最佳无模型算法, 同时所需 episode 数减少约 200 $\times$, 计算时间相当或更少。结果说明, 在图像领域中学习用于规划的潜在动力学模型是一条有前景的路线。

未来工作可以学习时间抽象, 而不是使用固定动作重复, 例如通过层级模型实现。为进一步提升最终性能, 可以学习价值函数, 用于近似规划时域之外的奖励总和。此外, 基于梯度的规划可能提高智能体的计算效率; 无需重建的表征学习也有助于处理视觉多样性更




图 5: 不同智能体设计的比较。图中展示测试性能随已收集回合数的变化。我们比较 PlaNet 、一个使用随机动作收集数据的版本 (random collection), 以及一个在每个环境步从 1000 条动作序列中选择最优序列、但不通过 CEM 迭代细化规划的版本 (random shooting)。曲线表示中位数, 阴影区域表示在 5 个随机种子和 10 条轨迹上得到的第 5 到第 95 百分位范围。

表 1: 将 PlaNet 与 Tassa et al. (2018) 报告的无模型算法 A3C 和 D4PG 进行比较。对应训练曲线在其论文图 4 中以橙色线显示, 在图 6 中以实线绿色线显示。我们据此估计 D4PG 达到 PlaNet 最终性能所需的 episode 数, 以估计数据效率增益。我们还加入使用真实模拟器而非学得动力学的 CEM 规划 ($H = 12, I = 10, J = 1000, K = 100$), 作为性能上界的估计。数字表示 5 个随机种子、10 条轨迹上的平均最终性能。

方法	模式	诗集	Cartpole Swing Up	Reacher Easy	Cheetah Run	Finger Spin	Cup Catch	Walker Walk
A3C	自主性	100,000	558	285	214	129	105	311
D4PG	像素	100,000	862	967	524	985	980	968
PlaNet (我们)	像素	1,000	821	832	662	700	930	951
CEM + 真模拟器	模拟状态	0	850	964	656	825	993	994
Data efficiency gain PlaNet over D4PG (factor)			250	40	500+	300	100	90

高的任务。本文工作还为通过共享动力学模型进行多任务控制提供了一个起点。

鸣谢 我们感谢雅各布·巴克曼、尼古拉·海斯、约翰·舒尔曼、里沙布·阿加尔瓦尔、西尔维乌·皮蒂斯、穆罕默德·诺鲁齐、乔治·塔克、戴维·杜维诺、谢恩·古、切尔西·芬、史蒂文·博赫兹、吉米·巴、陈芬妮和刘珍妮进行了有益的讨论。

参考文献

- Agrawal, P., Nair, A. V., Abbeel, P., Malik, J., and Levine, S. Learning to poke by poking: Experiential learning of intuitive physics. In *Advances in Neural Information Processing Systems*, pp. 5074–5082, 2016.
- Amos, B., Dinh, L., Cabi, S., Rothörl, T., Muldal, A., Erez, T., Tassa, Y., de Freitas, N., and Denil, M. Learning awareness models. In *International Conference on Learning Representations*, 2018.
- Babaeizadeh, M., Finn, C., Erhan, D., Campbell, R. H., and Levine, S. Stochastic variational video prediction. *arXiv preprint arXiv:1710.11252*, 2017.
- Banijamali, E., Shu, R., Ghavamzadeh, M., Bui, H., and Ghodsi, A. Robust locally-linear controllable embedding. *arXiv preprint arXiv:1710.05373*, 2017.
- Barth-Maron, G., Hoffman, M. W., Budden, D., Dabney, W., Horgan, D., Muldal, A., Heess, N., and Lillicrap, T. Distributed distributional deterministic policy gradients. *arXiv preprint arXiv:1804.08617*, 2018.
- Bengio, S., Vinyals, O., Jaitly, N., and Shazeer, N. Scheduled sampling for sequence prediction with recurrent neural networks. In *Advances in Neural Information Processing Systems*, pp. 1171–1179, 2015.
- Buckman, J., Hafner, D., Tucker, G., Brevdo, E., and Lee, H. Sample-efficient reinforcement learning with stochastic ensemble value expansion. *arXiv preprint arXiv:1807.01675*, 2018.
- Buesing, L., Weber, T., Racaniere, S., Eslami, S., Rezende, D., Reichert, D. P., Viola, F., Besse, F., Gregor, K., Hassabis, D., et al. Learning and querying fast generative models for reinforcement learning. *arXiv preprint arXiv:1802.03006*, 2018.
- Chiappa, S., Racaniere, S., Wierstra, D., and Mohamed, S. Recurrent environment simulators. *arXiv preprint arXiv:1704.02254*, 2017.
- Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., and Bengio, Y. Learning phrase representations using rnn encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*, 2014.
- Chua, K., Calandra, R., McAllister, R., and Levine, S. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. *arXiv preprint arXiv:1805.12114*, 2018.
- Chung, J., Kastner, K., Dinh, L., Goel, K., Courville, A. C., and Bengio, Y. A recurrent latent variable model for sequential data. In *Advances in neural information processing systems*, pp. 2980–2988, 2015.
- Clevert, D.-A., Unterthiner, T., and Hochreiter, S. Fast and accurate deep network learning by exponential linear units (elus). *arXiv preprint arXiv:1511.07289*, 2015.
- Deisenroth, M. and Rasmussen, C. E. Pilco: A model-based and data-efficient approach to policy search. In *Proceedings of the 28th International Conference on machine learning (ICML-11)*, pp. 465–472, 2011.
- Denton, E. and Fergus, R. Stochastic video generation with a learned prior. *arXiv preprint arXiv:1802.07687*, 2018.
- Dillon, J. V., Langmore, I., Tran, D., Brevdo, E., Vasudevan, S., Moore, D., Patton, B., Alemi, A., Hoffman, M., and Saurous, R. A. Tensorflow distributions. *arXiv preprint arXiv:1711.10604*, 2017.
- Doerr, A., Daniel, C., Schiegg, M., Nguyen-Tuong, D., Schaal, S., Toussaint, M., and Trimpe, S. Probabilistic recurrent state-space models. *arXiv preprint arXiv:1801.10395*, 2018.
- Ebert, F., Finn, C., Dasari, S., Xie, A., Lee, A., and Levine, S. Visual foresight: Model-based deep reinforcement learning for vision-based robotic control. *arXiv preprint arXiv:1812.00568*, 2018.
- Finn, C. and Levine, S. Deep visual foresight for planning robot motion. In *Robotics and Automation (ICRA), 2017 IEEE International Conference on*, pp. 2786–2793. IEEE, 2017.
- Gal, Y., McAllister, R., and Rasmussen, C. E. Improving pilco with bayesian neural network dynamics models. In *Data-Efficient Machine Learning workshop, ICML*, 2016.
- Gemici, M., Hung, C.-C., Santoro, A., Wayne, G., Mohamed, S., Rezende, D. J., Amos, D., and Lillicrap, T. Generative temporal models with memory. *arXiv preprint arXiv:1702.04649*, 2017.
- Gregor, K. and Besse, F. Temporal difference variational auto-encoder. *arXiv preprint arXiv:1806.03107*, 2018.
- Ha, D. and Schmidhuber, J. World models. *arXiv preprint arXiv:1803.10122*, 2018.

- Henaff, M., Whitney, W. F., and LeCun, Y. Model-based planning with discrete and continuous actions. *arXiv preprint arXiv:1705.07177*, 2018.
- Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., Mohamed, S., and Lerchner, A. beta-vae: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations*, 2016.
- Higuera, J. C. G., Meger, D., and Dudek, G. Synthesizing neural network controllers with probabilistic model based reinforcement learning. *arXiv preprint arXiv:1803.02291*, 2018.
- Igl, M., Zintgraf, L., Le, T. A., Wood, F., and Whiteson, S. Deep variational reinforcement learning for pomdps. *arXiv preprint arXiv:1806.02426*, 2018.
- Kalchbrenner, N., Oord, A. v. d., Simonyan, K., Danihelka, I., Vinyals, O., Graves, A., and Kavukcuoglu, K. Video pixel networks. *arXiv preprint arXiv:1610.00527*, 2016.
- Kalweit, G. and Boedecker, J. Uncertainty-driven imagination for continuous deep reinforcement learning. In *Conference on Robot Learning*, pp. 195–206, 2017.
- Karl, M., Soelch, M., Bayer, J., and van der Smagt, P. Deep variational bayes filters: Unsupervised learning of state space models from raw data. *arXiv preprint arXiv:1605.06432*, 2016.
- Kingma, D. P. and Ba, J. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- Kingma, D. P. and Dhariwal, P. Glow: Generative flow with invertible 1x1 convolutions. *arXiv preprint arXiv:1807.03039*, 2018.
- Kingma, D. P. and Welling, M. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- Krishnan, R. G., Shalit, U., and Sontag, D. Deep kalman filters. *arXiv preprint arXiv:1511.05121*, 2015.
- Krishnan, R. G., Shalit, U., and Sontag, D. Structured inference networks for nonlinear state space models. In *AAAI*, pp. 2101–2109, 2017.
- Kurutach, T., Clavera, I., Duan, Y., Tamar, A., and Abbeel, P. Model-ensemble trust-region policy optimization. *arXiv preprint arXiv:1802.10592*, 2018.
- Lamb, A. M., GOYAL, A. G. A. P., Zhang, Y., Zhang, S., Courville, A. C., and Bengio, Y. Professor forcing: A new algorithm for training recurrent networks. In *Advances In Neural Information Processing Systems*, pp. 4601–4609, 2016.
- Mathieu, M., Couprie, C., and LeCun, Y. Deep multi-scale video prediction beyond mean square error. *arXiv preprint arXiv:1511.05440*, 2015.
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529, 2015.
- Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T., Harley, T., Silver, D., and Kavukcuoglu, K. Asynchronous methods for deep reinforcement learning. In *International Conference on Machine Learning*, pp. 1928–1937, 2016.
- Moerland, T. M., Broekens, J., and Jonker, C. M. Learning multimodal transition dynamics for model-based reinforcement learning. *arXiv preprint arXiv:1705.00470*, 2017.
- Moravčík, M., Schmid, M., Burch, N., Lisý, V., Morrill, D., Bard, N., Davis, T., Waugh, K., Johanson, M., and Bowling, M. Deepstack: Expert-level artificial intelligence in heads-up no-limit poker. *Science*, 356(6337):508–513, 2017.
- Nagabandi, A., Kahn, G., Fearing, R. S., and Levine, S. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning. *arXiv preprint arXiv:1708.02596*, 2017.
- Nair, V. and Hinton, G. E. Rectified linear units improve restricted boltzmann machines. In *Proceedings of the 27th international conference on machine learning (ICML-10)*, pp. 807–814, 2010.
- Oh, J., Guo, X., Lee, H., Lewis, R. L., and Singh, S. Action-conditional video prediction using deep networks in atari games. In *Advances in Neural Information Processing Systems*, pp. 2863–2871, 2015.
- Rezende, D. J., Mohamed, S., and Wierstra, D. Stochastic backpropagation and approximate inference in deep generative models. *arXiv preprint arXiv:1401.4082*, 2014.
- Richards, A. G. *Robust constrained model predictive control*. PhD thesis, Massachusetts Institute of Technology, 2005.

- Rubinstein, R. Y. Optimization of computer simulation models with rare events. *European Journal of Operational Research*, 99(1):89–112, 1997.
- Silver, D., Schrittwieser, J., Simonyan, K., Antonoglou, I., Huang, A., Guez, A., Hubert, T., Baker, L., Lai, M., Bolton, A., et al. Mastering the game of go without human knowledge. *Nature*, 550(7676):354, 2017.
- Srinivas, A., Jabri, A., Abbeel, P., Levine, S., and Finn, C. Universal planning networks. *arXiv preprint arXiv:1804.00645*, 2018.
- Talvitie, E. Model regularization for stable sample rollouts. In *UAI*, pp. 780–789, 2014.
- Tassa, Y., Erez, T., and Todorov, E. Synthesis and stabilization of complex behaviors through online trajectory optimization. In *Intelligent Robots and Systems (IROS), 2012 IEEE/RSJ International Conference on*, pp. 4906–4913. IEEE, 2012.
- Tassa, Y., Doron, Y., Muldal, A., Erez, T., Li, Y., Casas, D. d. L., Budden, D., Abdolmaleki, A., Merel, J., Lefrancq, A., et al. Deepmind control suite. *arXiv preprint arXiv:1801.00690*, 2018.
- van den Oord, A., Vinyals, O., et al. Neural discrete representation learning. In *Advances in Neural Information Processing Systems*, pp. 6309–6318, 2017.
- Venkatraman, A., Hebert, M., and Bagnell, J. A. Improving multi-step prediction of learned time series models. In *AAAI*, pp. 3024–3030, 2015.
- Vondrick, C., Pirsiaavash, H., and Torralba, A. Generating videos with scene dynamics. In *Advances In Neural Information Processing Systems*, 2016.
- Watter, M., Springenberg, J., Boedecker, J., and Riedmiller, M. Embed to control: A locally linear latent dynamics model for control from raw images. In *Advances in neural information processing systems*, pp. 2746–2754, 2015.
- Wayne, G., Hung, C.-C., Amos, D., Mirza, M., Ahuja, A., Grabska-Barwinska, A., Rae, J., Mirowski, P., Leibo, J. Z., Santoro, A., et al. Unsupervised predictive memory in a goal-directed agent. *arXiv preprint arXiv:1803.10760*, 2018.
- Weber, T., Racanière, S., Reichert, D. P., Buesing, L., Guez, A., Rezende, D. J., Badia, A. P., Vinyals, O., Heess, N., Li, Y., et al. Imagination-augmented agents for deep reinforcement learning. *arXiv preprint arXiv:1707.06203*, 2017.
- Zhang, M., Vikram, S., Smith, L., Abbeel, P., Johnson, M., and Levine, S. SOLAR: deep structured representations for model-based reinforcement learning. *arXiv preprint arXiv:1808.09105*, 2018.

A. 超参数

我们采用Ha & Schmidhuber (2018) 中的卷积和反卷积网络，在动力学模型中使用包含 200 个单元的 GRU (Cho et al., 2014) 作为确定性路径，并将其他函数实现为两个大小为 200、带 ReLU 激活的全连接层 (Nair & Hinton, 2010)。潜在空间中的分布为 30 维对角高斯分布，其均值和标准差由模型预测。

我们按照Kingma & Dhariwal (2018) 的做法，将图像比特深度降至 5 bit 作为预处理。模型使用 Adam 优化器训练 (Kingma & Ba, 2014)，学习率为 10^{-3} ， $\epsilon = 10^{-4}$ ，梯度裁剪范数为 1000；批次由 $B = 50$ 个长度为 $L = 50$ 的序列片段组成。我们没有相对于重建项缩放 KL 散度项，而是通过将散度损失裁剪到不低于该值，给予模型 3 个 free nats。在智能体的早期版本中，我们使用过潜在过冲和一个额外固定的全局先验，但后来发现它们并非必要。

规划时，我们使用 CEM，规划视野长度 $H = 12$ ，优化迭代次数 $I = 10$ ，候选样本数 $J = 1000$ ，并用最优的 $K = 100$ 条序列重新拟合分布。训练从 $S = 5$ 个随机动作种子回合开始；之后每经过 $C = 100$ 个更新步骤就额外收集一个回合，并加入 $\epsilon \sim \text{Normal}(0, 0.3)$ 的动作噪声。动作重复次数因域而异：cartpole ($R = 8$)、reacher ($R = 4$)、cheetah ($R = 4$)、finger ($R = 2$)、cup ($R = 4$)、walker ($R = 2$)。我们发现重要的超参数包括动作重复次数、KL 散度尺度 β 和学习率。

B. 规划算法

算法 2: Latent planning with CEM

Input:	H Planning horizon distance	$q(s_t \mid o_{\leq t}, a_{< t})$	Current state belief
	I Optimization iterations	$p(s_t \mid s_{t-1}, a_{t-1})$	Transition model
	J Candidates per iteration	$p(r_t \mid s_t)$	Reward model
	K Number of top candidates to fit		

```

1 Initialize factorized belief over action sequences  $q(a_{t:t+H}) \leftarrow \text{Normal}(0, \mathbb{I})$ .
2 for optimization iteration  $i = 1..I$  do
    // Evaluate  $J$  action sequences from the current belief.
3   for candidate action sequence  $j = 1..J$  do
4        $a_{t:t+H}^{(j)} \sim q(a_{t:t+H})$ 
5        $s_{t:t+H+1}^{(j)} \sim q(s_t \mid o_{1:t}, a_{1:t-1}) \prod_{\tau=t+1}^{t+H+1} p(s_\tau \mid s_{\tau-1}, a_{\tau-1}^{(j)})$ 
6        $R^{(j)} = \sum_{\tau=t+1}^{t+H+1} \mathbb{E}[p(r_\tau \mid s_\tau^{(j)})]$ 
    // Re-fit belief to the  $K$  best action sequences.
7    $\mathcal{K} \leftarrow \text{argsort}(\{R^{(j)}\}_{j=1}^J)_{1:K}$ 
8    $\mu_{t:t+H} = \frac{1}{K} \sum_{k \in \mathcal{K}} a_{t:t+H}^{(k)}$ ,  $\sigma_{t:t+H} = \frac{1}{K-1} \sum_{k \in \mathcal{K}} |a_{t:t+H}^{(k)} - \mu_{t:t+H}|$ .
9    $q(a_{t:t+H}) \leftarrow \text{Normal}(\mu_{t:t+H}, \sigma_{t:t+H}^2 \mathbb{I})$ 
10 return first action mean  $\mu_t$ .
```

C. 多任务学习




图 6: 我们比较了在所有任务上共同训练的单个 PlaNet 智能体与分别训练的多个 PlaNet 智能体。图中展示测试性能随每个任务已收集回合数的变化。单个智能体能够学会解决所有任务，但学习速度慢于分别训练的智能体。曲线表示 6 个任务、5 个随机种子和 10 条轨迹上的均值，阴影区域表示 1 个标准差。




图 7: 在六个任务上共同训练的单个 PlaNet 智能体的逐任务性能。图中展示测试性能随每个任务已收集回合数的变化。智能体不会被告知当前任务类型，必须从图像观测中自行推断。结果表明，该智能体能够区分任务并解决它们，但学习速度会有一定下降。曲线表示中位数，阴影区域表示在 4 个随机种子和 10 条轨迹上得到的第 5 到第 95 百分位范围。

D. 潜在过冲




图 8: 我们在本文提出的 RSSM 以及另一个称为 DRNN 的模型上, 比较标准变分目标与潜在过冲。DRNN 使用两个 RNN 分别作为编码器和解码器, 中间包含一段随机状态序列。潜在过冲能显著提升 DRNN 以及其他测试过的模型的性能 (图中未展示), 但会使 RSSM 的性能略有下降。曲线表示中位数, 阴影区域表示在 5 个随机种子和 10 条轨迹上得到的第 5 到第 95 百分位范围。

E. 激活函数




图 9: 硬 ReLU (Nair & Hinton, 2010) 与平滑 ELU (Clevert et al., 2015) 激活函数的比较。实验表明, 平滑激活有助于提升纯随机模型 (以及纯确定性模型, 图中未展示) 的性能, 而本文提出的 RSSM 对激活函数选择较为稳健。曲线表示中位数, 阴影区域表示在 5 个随机种子和 10 条轨迹上得到的第 5 到第 95 百分位范围。

F. 下界推导

单步预测分布 对于潜在动力学模型 $p(o_{1:T}, s_{1:T} | a_{1:T}) = \prod_t p(s_t | s_{t-1}, a_{t-1})p(o_t | s_t)$ 以及变分后验 $q(s_{1:T} | o_{1:T}, a_{1:T}) = \prod_t q(s_t | o_{\leq t}, a_{< t})$, 可由重要性加权 和 Jensen 不等式得到如下变分下界:

$$\begin{aligned}
 \ln p(o_{1:T} | a_{1:T}) &\triangleq \ln \mathbb{E}_{p(s_{1:T}|a_{1:T})} \left[\prod_{t=1}^T p(o_t | s_t) \right] \\
 &= \ln \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\prod_{t=1}^T p(o_t | s_t) p(s_t | s_{t-1}, a_{t-1}) / q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &\geq \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\sum_{t=1}^T \ln p(o_t | s_t) + \ln p(s_t | s_{t-1}, a_{t-1}) - \ln q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &= \sum_{t=1}^T \left(\underbrace{\frac{\mathbb{E}[\ln p(o_t | s_t)]}{q(s_t | o_{\leq t}, a_{< t})}}_{\text{reconstruction}} - \underbrace{\mathbb{E}[\text{KL}[q(s_t | o_{\leq t}, a_{< t}) \parallel p(s_t | s_{t-1}, a_{t-1})]]}_{\text{complexity}} \right).
 \end{aligned} \tag{8}$$

多步骤预测分布 对 d 步预测分布 $p_d(o_{1:T}, s_{1:T} | a_{1:T}) = \prod_t p(s_t | s_{t-d}, a_{t-d-1:t-1})p(o_t | s_t)$ 和变分后验 $q(s_{1:T} | o_{1:T}, a_{1:T}) = \prod_t q(s_t | o_{\leq t}, a_{< t})$, 可以得到类似的下界。第二个不等式来自将对数移入多步先验项; 这些先验满足递推关系 $p(s_t | s_{t-d}, a_{t-d-1:t-1}) = \mathbb{E}_{p(s_{t-1}|s_{t-d}, a_{t-d-1:t-2})}[p(s_t | s_{t-1}, a_{t-1})]$ 。

$$\begin{aligned}
 \ln p_d(o_{1:T} | a_{1:T}) &\triangleq \ln \mathbb{E}_{p_d(s_{1:T}|a_{1:T})} \left[\prod_{t=1}^T p(o_t | s_t) \right] \\
 &= \ln \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\prod_{t=1}^T p(o_t | s_t) p(s_t | s_{t-d}, a_{t-d-1:t-1}) / q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &\geq \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\sum_{t=1}^T \ln p(o_t | s_t) + \ln p(s_t | s_{t-d}, a_{t-d-1:t-1}) - \ln q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &\geq \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\sum_{t=1}^T \ln p(o_t | s_t) + \underbrace{\mathbb{E}[\ln p(s_t | s_{t-d}, a_{t-d-1:t-1})]}_{p(s_{t-1}|s_{t-d}, a_{t-d-1:t-2})} - \ln q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &= \sum_{t=1}^T \left(\underbrace{\frac{\mathbb{E}_{q(s_t|o_{\leq t}, a_{< t})}[\ln p(o_t | s_t)]}{\text{reconstruction}}} - \underbrace{\frac{\mathbb{E}[\text{KL}[q(s_t | o_{\leq t}, a_{< t}) \parallel p(s_t | s_{t-d}, a_{t-d-1:t-1})]]}{p(s_{t-1}|s_{t-d}, a_{t-d-1:t-2})q(s_{t-d}|o_{\leq t-d}, a_{< t-d})}}_{\text{multi-step prediction}} \right).
 \end{aligned} \tag{9}$$

由于所有期望都位于目标外层, 可以直接用样本均值替换期望, 从而得到该下界的无偏估计。

单步和多步预测分布之间的关系 我们猜想, 在数据集期望意义下, 多步预测分布 $p_d(o_{1:T})$ 是同一潜在序列模型中单步预测分布 $p(o_{1:T})$ 的下界。由于潜在状态序列满足 Markov 性质, 对于 $d \geq 1$, 数据处理不等式给出:

$$\begin{aligned}
 I(s_t; s_{t-d}) &\leq I(s_t; s_{t-1}) \\
 H(s_t) - H(s_t | s_{t-d}) &\leq H(s_t) - H(s_t | s_{t-1}) \\
 \mathbb{E}[\ln p(s_t | s_{t-d})] &\leq \mathbb{E}[\ln p(s_t | s_{t-1})] \\
 \mathbb{E}[\ln p_d(o_{1:T})] &\leq \mathbb{E}[\ln p(o_{1:T})].
 \end{aligned} \tag{10}$$

因此, 对多步预测分布的任何下界, 包括 Equation 9 和 Equation 7, 也都是单步预测分布的下界。

G. 其他相关工作

状态空间规划 当智能体能够访问环境的低维状态时，可以直接在状态空间中学习动力学。在状态变量很少的控制任务中，例如 cartpole 和 mountain car, PILCO (Deisenroth & Rasmussen, 2011) 使用高斯过程建模动力学，并取得了很高的样本效率。使用神经网络动力学模型的类似方法可以解决双连杆平衡问题 (Gal et al., 2016; Higuera et al., 2018)，也可以通过梯度进行规划 (Henaff et al., 2018)。Chua et al. (2018) 使用神经网络集成，并将方法扩展到 cheetah run 任务。这些方法的局限在于，它们可以访问底层系统的低维 Markov 状态，有时还可以访问奖励函数。Amos et al. (2018) 在机器人手主动探索中使用观测空间过冲来训练确定性模型。相比之下，我们不依赖低维状态表示，而是使用潜在动力学模型解决来自图像的控制任务。

混合智能体 基于模型的 RL 面临若干挑战，这促使研究者提出混合智能体：有的方法通过在想象经验上训练来加速策略学习 (Kalweit & Boedecker, 2017; Nagabandi et al., 2017; Kurutach et al., 2018; Buckman et al., 2018; Ha & Schmidhuber, 2018)，有的方法改进特征表示 (Wayne et al., 2018; Igl et al., 2018)，也有方法直接利用模型包含的信息 (Weber et al., 2017)。Srinivas et al. (2018) 学习一个集成规划计算的策略网络，用强化学习训练且不使用预测损失，但训练时需要专家示范。

多步骤预测 研究者已经探索多年如何用多步预测训练序列模型。Scheduled sampling (Bengio et al., 2015) 会在训练过程中改变序列模型的展开距离。Hallucinated replay (Talvitie, 2014) 将预测结果混入数据集，从而间接训练多步预测。Venkatraman et al. (2015) 采用模仿学习视角；最近，Amos et al. (2018) 同时针对所有多步预测训练动力学模型。我们将这一思路推广到通过变分推断训练的潜在序列模型。

潜在序列模型 早期工作已经研究过非马尔可夫观测序列的建模，包括带确定性隐藏状态的循环神经网络 (RNN) 和概率状态空间模型 (SSM)。变分自编码器的思想 (Kingma & Welling, 2013; Rezende et al., 2014) 推动了通过变分推断训练非线性 SSM 的方法 (Krishnan et al., 2015)。VRNN (Chung et al., 2015) 将 RNN 与 SSM 结合，并同样用变分推断训练。与我们的 RSSM 不同，它会把生成的观测反馈回模型，因此前向预测代价较高。Karl et al. (2016) 通过限制转移函数来缓解塌缩到单一未来的问题，Moerland et al. (2017) 关注多模态转移，Doerr et al. (2018) 则稳定了纯随机模型的训练。Buesing et al. (2018) 提出了与我们相似的模型，但将其用于混合智能体，而不是用于显式规划。

视频预测 视频预测是深度学习中的活跃研究方向。Oh et al. (2015) 和 Chiappa et al. (2017) 使用确定性模型在 Atari 游戏中得到视觉上可信的预测。Kalchbrenner et al. (2016) 提出自回归视频预测模型，使用带门控的 CNN 和 LSTM。近期方法为模型引入随机性，以捕捉多个可能未来 (Babaeizadeh et al., 2017; Denton & Fergus, 2018)。为获得更真实的预测，Mathieu et al. (2015) 和 Vondrick et al. (2016) 使用对抗损失。在模拟环境中，Gemici et al. (2017) 用外部记忆增强动力学模型，以记住长期上下文。van den Oord et al. (2017) 提出一种变分模型，通过最近邻查找避免采样，从而得到高保真图像预测。这些模型与我们的方法互为补充。

H. 视频预测




图 10: 测试片段上的开环视频预测。columns 1-5 显示重建得到的上下文帧, 其余图像由模型开环生成。在 cheetah 环境中, RSSM 能在未来 50 个时间步内给出像素级准确的预测。动作序列随机选自与训练回合同步收集、并带有动作噪声的测试回合。

I. 状态诊断




图 11: 开环状态诊断。我们冻结 PlaNet 智能体的动力学模型，并训练小型神经网络来预测模拟器的真实位置、速度和奖励。这些量的开环预测表明，底层系统的大部分信息都保存在学习到的潜在空间中，并且能够在超过本文规划时域的范围保持较准确的前向预测。

J. 规划参数




图 12: 使用真实模拟器、在不同规划器设置下得到的 cheetah running 任务规划性能。性能范围为 132 (蓝色) 到 837 (黄色)。评估更多动作序列、进行更多优化迭代, 并只用较少数量的最优候选序列重新拟合分布, 通常会提升性能。规划时域为 6 步时长度不足, 因此性能较差; 更长的规划时域又会扩大搜索空间并损害性能。在该环境中, 最佳规划时域接近 8 步。